

인공지능(머신러닝)을 활용한 대함 무기효과 추정방안 연구

김선준* 노상현** 김종현***

- 서론
- 무기효과 산출 및 분석
- 인공지능(머신러닝) 예측방법론
- 대함 무기효과 추정 및 검증
- 결론

Abstract

A Study on Estimation of Naval Weapon Effects Using Artificial Intelligence (Machine learning)

This paper is a study of estimating naval weapon effects using machine learning based on weapon effect data derived from the JMEM Weaponneering System(JWS) developed by the U.S. Joint Technical Coordinating Group for Munitions Effectiveness (JTCG/ME).

Machine learning was applied using 2,498 data points including specifications of anti-ship systems within the JWS, as well as engagement conditions. The data obtained through Ship Weaponneering Estimation Tool(SWET) integrated in the JWS.

Six machine learning methodologies, commonly used in data analysis, were selected and predictive models were developed using each of them. The results indicated that the Extra Trees methodology demonstrated the highest level of accuracy.

Keywords: Artificial Intelligence, Machine Learning, Navy, Weapon Effectiveness, JMEM Weaponneering System(JWS), Joint Munitions Effectiveness Manual(JMEM)

* 합동참모본부 분석실험실, 해군 소령, 산업공학 석사, sunjoon90@naver.com
** 한국국방연구원 연구위원, 정보통신공학 학사, hyunsfc@kida.re.kr
*** 한국국방연구원 연구원, 선박해양공학 학사, kjhjh@kida.re.kr

I. 서론

무기효과 분석은 무기체계와 표적의 조합에 대해 피해율을 산정하는 정량적인 분석방법을 의미한다. 한국군의 무기효과 분석은 1990년대부터 최근까지 미군으로부터 도입한 JMEM(합동무기효과편람)¹⁾ 자료 및 JWS(합동무기추천체계)²⁾와 같은 무기효과 분석 도구에 기초를 두고 있는데, 이를 바탕으로 한국군은 무기효과 분석 역량을 강화하기 위해 다양한 노력을 수행해 왔다.

무기효과 분석의 필수 요소인 기초데이터는 작전계획 수립, 전력소요 분석, 무기체계 개발 등 다양한 분야에서 활용되며(이승우 외, 2018), 그 중요성은 날로 증대되고 있다. 한국군의 경우 무기효과 기초데이터 내실화에 많은 노력을 기울이고 있는데, 그 이유는 한국군이 보유한 무기효과 기초데이터 중에서 미군에서 도입한 무기체계의 데이터가 상당 부분을 차지하기 때문이다. 또한 국내 개발 무기체계의 경우 데이터 생산에 많은 시간과 인력, 비용이 소요되기 때문에 신뢰성 높은 무기효과 데이터를 구축하기에는 현실적으로 많은 제약이 따르게 된다.

본 연구에서는 무기효과 데이터 중에서도 특히 데이터가 부족한 대함 무기효과 데이터를 추정하기 위해 인공지능 데이터 분석기법 중 하나인 머신러닝 지도학습을 활용하였다. 그 이유는 다음과 같은 머신러닝의 특징에서 찾아볼 수 있다. 첫째, 대함 무기효과 데이터와 같이 적은 양의 데이터에 대해서도 머신러닝을 활용하여 학습 및 예측이 가능하기 때문이다. 둘째, 고도로 발달된 컴퓨팅 기술과 더불어 머신러닝의 예측 성능도 향상되어 예측 분야에서 높은 정확도를 보이기 때문이다. 셋째, 머신러닝이 데이터의 특징을 스스로 학습하고 패턴을 파악하기 때문에, 사람의 개입 없이도 스스로 예측 결과를 제공해주는 특성을 갖고 있기 때문이다.

머신러닝에는 예측을 위한 다양한 방법론이 있지만, 본 연구에서는 보편적으로

1) 합동무기효과편람(Joint Munitions Effectiveness Manual): 각종 무기체계의 효과도 평가와 무기의 소요량 예측을 위한 기초자료와 기법을 수록한 것으로, 미국에서는 각급 전술 지휘관들이 손쉽게 참고할 수 있도록 널리 배포되어 활용되고 있다.

2) 합동무기추천체계(JMEM Weaponeeing System): 군사작전분석, 연구개발획득, 전력소요분석 등을 위해 美 합동무기효과기술조정단(JTCG/ME)에서 개발한 공대지 및 지대지 무기체계의 무기효과자료와 무기효과분석도구를 포함하는 CD형태의 통합패키지

활용되는 6가지 예측방법론을 활용하였다. 학습데이터는 JWS에서 산출한 대함 무기효과 추정데이터 약 2,500여 건으로 구성하였으며, 각각의 방법론을 활용하여 예측모델을 생성하였다. 그중 가장 우수한 성능을 보이는 예측모델을 선정하여 예측 결과를 검증하는 절차로 연구를 수행하였다.

Ⅱ. 무기효과 산출 및 분석

1. 무기효과 산출

무기효과란 단일 무기체계 간의 교전 시 무기체계와 목표물 간의 효과도를 실험 및 시뮬레이션을 통해 평가한 것으로, 무기체계와 탄종, 신관 등의 변수와 표적의 상태, 낙각, 사거리, 피해유형 등의 변수에 대하여 살상확률, 살상면적 등의 척도로 수치화한 자료이다.

무기효과 산출은 무기체계 특성, 투하정밀도, 표적 취약성과 같은 제반 요소들을 고려하여 작전 교전 상황과 표적-무기 상호분석에 따라 이루어진다. 즉, 개별 무기의 효과는 무기체계의 기본제원뿐만 아니라 전장에서 발생할 수 있는 모든 여건이 종합적으로 반영되어 산출된다(문형곤 외, 2004).



<그림 1> 무기효과 산출 절차

2. 미군의 무기효과 분석

가. 합동탄약효과 기술조정 사무국(JTCG/ME)

미국에서는 1960년대 초까지 무기효과를 산출하는 방법에 있어 각 군이 무기효과를 산출하는 고유한 방법을 가지고 있었고, 동일한 교전조건에 대해 각군이 각각 다른 결과를 산출하여 사용해 왔다. 이러한 노력을 통합하고자 1963년에 합동군 워킹 그룹(Joint Service working group)이 만들어졌고 이 그룹은 무기효과를 결정하는 다양한 구성요소 작업을 하나로 통합하는 작업을 수행했으며, 결과적으로 1965년 합동탄약효과 기술조정 사무국(JTCG/ME)³⁾이 설립되었다.

JTCG/ME는 지난 60여 년 동안 지대지, 공대지, 대공 무기체계에 대한 자료체계 및 분석 도구를 개발해 왔다. 2007년에 JWS(합동무기추천체계)를 개발하였고, 현재까지도 성능개량 사업을 지속 수행하고 있다. JTCG/ME 임무는 모든 비핵무기에 대한 운용 효과 추정치를 개발하는 것이며, 이렇게 개발된 JWS는 육군, 해군, 공군, 해병대의 승인을 받아 운용하고 있다.

나. 합동무기추천체계(JWS)

JWS는 작전 지휘관, 표적과 무장계획 담당자, 무기 시스템 설계 및 군수 담당자를 위해 무기 효과를 제공하는 도구이며, 공대지(Air to Surface)와 지대지(Surface to Surface) 재래식 무기체계를 포함하고 있

단독 모델	내부 연동모델
 COVART 표적 취약성 분석	 JCAT 신규 무장효과 자료 탑재
 PVTM 장갑차량 직사화기효과분석	 FIST / IMEA 구조물 피해 분석(건물/병커)
 KEPPEN 절감탄 관통력 측정	 SWET 해상함 피해효과 분석
 FATEPEN 항공기 표적 관통력 분석	 ELP 탄두 관통 효과분석
 JMAE 평균 피해효과 면적 분석	 JSWM 정밀 자탄 효과 분석
 ProjPEN 탄도 관통력 분석	 JDAP 공중 발사 정확도 분석
 AvMat 탄약 중첩효과 분석	 GWTS 유도무기 입체 탄도 분석

<그림 2> 합동무기추천체계(JWS) 연동모델

3) Joint Technical Coordinating Group for Munitions Effectiveness

다. JWS는 이동표적과 고정표적에 대한 공대지 및 지대지 무장의 확률적 효과를 산출해주며, 인증된 무기효과 산출 방법론과 수많은 기초데이터, 다양한 무기효과 분석 도구를 포함하고 있다.


3. 한국군의 무기효과 분석

현재 한국군은 무기효과 분석을 위해 미군의 JMEM 자료와 피해평가 방법론을 활용하고 있는데, 여기에는 다음과 같은 몇 가지 제한사항이 있다.

가. 무기효과 기초데이터 부족

미군의 JMEM 생산 방법론에 따르면 총 5단계를 거쳐 무기효과를 산출한다. 1단계 ‘정보수집단계’는 무기효과를 생산하고자 하는 표적과 무기체계의 기본적인 제원 및 특성을 수집한다. 2단계 ‘표적자료 개발단계’에서는 대상 표적을 3차원 형상모델로 개발한다. 3단계 ‘표적 취약성자료 생산단계’에서는 피해기준과 피해기구별 표적의 취약면적을 생산한다. 4단계 ‘효과지수 산출단계’에서는 특정 무장과 표적을 조합하여 다양한 효과지수를 산출한다. 5단계 ‘무기효과 산출단계’에서는 무기체계의 전달정확도를 고려하여 무기효과를 산출한다.

JMEM 생산 과정은 다양한 실험을 수반하며 때로는 2년 이상의 시간이 소요되는 과정으로서, 많은 인력과 비용이 요구된다. 따라서 한국군에서 운용 중인 모든 무기체계의 무기효과 기초데이터를 확보한다는 것은 현실적으로 불가능하다. 또한 무기체계 개발단계에서 무기효과 기초데이터가 산출되어야 하나, 시간과 비용, 실험환경의 제약 등으로 인해 사실상 무기효과 기초데이터 확보는 제한될 수밖에 없다.



<그림 3> JMEM(합동무기효과편람) 생산 절차(5단계)

나. 무기효과 분석 도구 필요

미군으로부터 도입한 JWS는 한국군의 무기효과 분석 능력을 향상시키는데 중요한 역할을 하였다.

하지만 JWS는 우리군이 미군으로부터 FMS(대외군사판매)⁴⁾방식으로 도입한 무기체계의 무기효과 자료만 포함되어 국내 개발 무기체계 및 미국 이외의 국가에서 도입한 무기체계의 효과분석에는 한계가 있다. 이와 같은 한계점은 대표적으로 JWS 내부 연동모델 중 하나인 SWET(수상함 피해효과 분석도구)⁵⁾에서 찾아볼 수 있다. SWET은 적성국 수상함 표적에 대한 미군 무기체계의 교전 조건을 입력하여 무기효과를 산출하는 기능으로서, 사용자는 제한된 교전 조건 입력값 범위 내에서만 무기효과 산출이 가능하다. 예를 들어 미군의 무기체계를 참고하여 개발된 한국군의 무기체계가 기존 대비 고성능 탐지 센서가 장착되어 정확도가 향상되었다

4) 대외군사판매(Foreign Military Sales): 미국이 자유 우방국과 동맹국에 대한 안보지원계획의 일환으로 「무기수출 통제법」과 관련 법규에 따라 군수물자와 장비를 판매하는 제도

5) Ship Weaponing Estimation Tool

면, SWET에서는 한국군 무기체계의 무기효과 산출이 제한되는 것이다.

또한 JWS는 프로그램 내 무기효과 산출방법론이 보안상 공개되지 않기 때문에, 이를 새로운 분석도구에 논리적으로 구현한다는 것은 불가능하다.

현재 한국군은 제한적으로나마 이를 극복하고자 한국군 무기체계 효과분석을 위해 가장 유사한 미군 무기체계와 비교, 대조하여 무기효과를 추정하고 있다. 하지만 궁극적으로는 한국군이 운용하는 무기체계에 가장 적합한 무기효과 분석 도구가 마련되어야 할 필요가 있다.

Ⅲ. 인공지능(머신러닝) 예측방법론

1. 인공지능 소개

오늘날 우리는 컴퓨팅 기술의 발전과 다양한 센서 및 데이터 처리 능력의 발전으로 4차 산업혁명⁶⁾ 시대에 살고 있다. 4차 산업혁명은 초연결(Hyper Connectivity)⁷⁾과 초지능(Hyper Intelligence)⁸⁾의 시대로서, 이는 기존의 산업혁명과 비교하여 사회 전반에 걸쳐 더 넓은 범위에 더 빠른 속도로 막대한 영향을 끼치고 있다. 4차 산업혁명을 이끌 다양한 기술 중에서도 인공지능, 특히 머신러닝 기술은 현재 데이터 활용 분야에서 주목받고 있는 기술이다. 그 이유는 머신러닝을 통해 다양한 데이터 확보는 물론, 많은 양의 데이터를 효과적으로 처리할 수 있게 되었기 때문이다.

6) 2016년 세계 경제 포럼(WEF, World Economic Forum)에서 언급되었으며, 정보통신기술(ICT) 기반의 새로운 산업 시대를 대표하는 용어가 되었다.


7) IT를 바탕으로 사람, 프로세스, 데이터, 사물이 서로 연결됨으로써 지능화된 네트워크를 구축하여 이를 통해 새로운 가치와 혁신의 창출이 가능해지는 사회

8) 인간지능과 인공지능의 협력을 통해 최적의 의사결정을 통해 문제 해결 등 더 나은 서비스를 제공하는 역량

<표 1> 스튜어드 러셀, 피터 노빅 인공지능 기술 분류(2016)

구분	내용
자연어처리	언어를 이용한 의사소통을 위한 자연어 처리
지식표현	알고있는 혹은 입력된 정보를 표현하기 위한 지식 표현
자동추론	입력된 정보를 활용해 질문에 답하고, 새로운 결론을 도출하기 위한 자동추론
기계학습	새로운 상황에 적응, 패턴을 외삽(extrapolation)하기 위한 기계학습
컴퓨터시각	물체를 인식하기 위한 컴퓨터 시각
로봇공학	물체를 조작하고 이동하기 위한 로봇공학

머신러닝은 인공지능의 한 분야로서, 1959년 Arthur Lee Samuel⁹⁾은 머신러닝을 ‘컴퓨터에 명시적인 프로그램 없이 배울 수 있는 능력을 부여하는 연구분야’라고 정의하였다. 즉, 사람이 학습하듯이 컴퓨터에도 유사한 능력을 부여하여 컴퓨터가 새로운 지식을 얻을 수 있는 연구분야인 것이다. 이는 데이터에서 규칙을 도출해 규칙에 따른 프로그램을 직접 작성하는 기존의 방식과는 확연한 차이가 있다.



<그림 4> 전통적인 프로그래밍과 머신러닝 비교

9) Arthur Lee Samuel(1901~1990), 미국의 컴퓨터 게임 및 인공지능 분야의 선구자

기존의 프로그래밍은 주로 데이터를 입력하여 명시적인 규칙에 따라 정확한 결과를 도출하는 데 중점을 둔다. 그러나 머신러닝은 데이터 내에서 패턴이나 규칙을 찾아내고, 이를 새로운 데이터에 적용하여 예측이나 분류를 수행한다는 점에서 기존의 프로그래밍과는 차이가 있다.


즉, 머신러닝은 이전에 수집된 데이터를 활용하여 미래에 발생할 가능성이 있는 사건을 예측하는 데에 활용할 수 있다. 이러한 예측은 데이터가 입력되고 시스템 내부에서 패턴을 ‘학습’하는 과정을 통해 이루어지며, ‘학습’을 통해 판단 기준이 정립된다. 그 후 새로운 데이터에 대해 답을 내려주는 것이다.

2. 머신러닝의 분류

머신러닝은 수집된 데이터를 학습하여 모델을 생성하는 방법론으로, 이 모델은 주어진 데이터를 기반으로 미래의 결과를 예측하는 데 사용된다. 모델은 데이터를 학습함으로써 입력에 대한 출력을 생성하며, 학습이 완료된 후에는 새로운 입력을 모델에 제공하여 예측 결과를 얻을 수 있다. 예를 들어, 예측 모델이 학습된 데이터를 기반으로 새로운 데이터를 제공하면 해당 모델이 예측 결과를 출력하는 것이다.

데이터 간의 상호 연결된 패턴이 반복적인 과정을 통해 발전하면서, 이러한 복잡한 패턴과 상관 관계는 그 규모와 복잡성으로 인해 사용자가 더욱 이해하기 어렵게 된다. 이는 인공지능을 활용하는 대부분의 분야에서 설명 가능한 인공지능 이슈가 제기되는 원인이기도 하다.

이러한 머신러닝은 학습형태에 따라 지도학습(Supervised Learning), 비지도학습(Unsupervised Learning), 그리고 강화학습(Reinforcement Learning)으로 구분할 수 있다.



<그림 5> 기계학습의 분류

가. 지도학습(Supervised Learning)

학습데이터로부터 하나의 함수를 유추해내기 위해 문제를 풀어보면서 학습하는 방식이다. 지도학습은 크게 회귀분석(Regression)과 분류(Classification)로 구분할 수 있다. 학습 데이터는 일반적으로 입력 객체에 대한 속성을 벡터 형태로 포함하고 있으며, 각 벡터에는 원하는 결과가 표시되어 있다. 이러한 함수 중에서 연속적인 값을 출력하는 것을 회귀분석(Regression)이라 하며, 입력 벡터가 특정 종류의 값인지를 구분하는 것을 분류(Classification)라고 한다.

나. 비지도학습(Unsupervised Learning)

정답이 없는 자료를 가지고 있는 상태에서 비슷한 성향을 지닌 데이터끼리 군집화(Clustering)하면서 문제를 풀어가는 방법론이다. 즉, 결과값 없이 입력값만을 이용하여 학습시키는 방식이다. 이것은 집단별로 분류한 뒤 높은 집단을 선택하여 이들 중심으로 집중 마케팅을 전개하는 것이다. 이 기법은 주로 마케팅 고객 그룹화에 적용된다.

다. 강화학습(Reinforcement Learning)


결과 대신 어떤 일을 잘했을 때 보상(Reward)을 주는 방법으로 학습하여 현재 상태(State)에서 어떤 행동을 취하는 것이 최적인지를 학습하는 것이다. 행동을 취할 때마다 외부환경에서 보상이 주어지는데 이러한 보상을 최대화하는 방향으로 학습을 진행시킨다.

3. 지도학습 예측방법론

본 연구에서 활용한 지도학습 예측방법론은 총 6가지이다. 다양한 방법론을 적용 시도한 이유는 각각의 예측방법론이 데이터의 속성과 특수성에 따라 다른 성능을 보이기 때문이다. 또한, 연구 목적상 다양한 모델을 적용하여 성능을 비교해보고, 궁극적으로 무기효과 데이터 특성에 가장 부합하는 방법론을 확인하고자 하였다.

가. K 최근접 이웃 분류(KNN) 방법론

K-최근접 이웃 분류(KNN, K-Nearest Neighbor) 방법론은 새로운 데이터에 대하여 기존의 학습 데이터 가운데 가장 가까운 K개의 이웃의 정보로 결과값을 예측하는 방법론이다. 회귀(Regression) 문제의 경우는 이웃하는 종속변수의 평균값이 예측값으로 사용될 수 있다.




<그림 6> 유클리디안 거리

나. 배깅(Bagging) 방법론

배깅(Bagging)은 Bootstrap Aggregating의 약자로, 주어진 데이터에 대해 여러


부트스트랩 샘플을 모델링한 후 이를 결합하여 최종 예측 모델을 생성하는 방법이다. 여기서, 부트스트랩 샘플이란 동일한 크기의 표본자료를 원천자료로부터 임의 복원/추출한 것을 의미한다. 배깅 방법론은 n 번의 랜덤 복원 샘플링을 수행하고 각 샘플의 모델링 결과를 결합하여 최종 모델을 생성한다. 즉, 여러 번의 복원 샘플링을 통해 예측 모델의 분산을 감소시켜 예측 성능을 향상시키는 방법론이다.



<그림 7> 배깅 방법론

다. 랜덤포레스트(Random Forest) 방법론

가장 강력한 성능을 보여주는 방법론 중 하나로서, 학습을 통해 구성해 놓은 다수의 의사결정트리로부터 분류결과를 취합하여 예측하는 앙상블 모델이다. 랜덤포레스트의 주요 특징 중 하나는 랜덤성에 의해 각 트리가 서로 조금씩 다른 특성을 갖는다는 점이다.



<그림 8> 랜덤 포레스트 방법론


다. 이때, 각 트리의 예측이 서로 비상관성을 갖도록 하여 결과적으로 일반화 성능을 향상시키는 구조이다. 일반적인 결정 트리를 사용하는 방법은 결과나 성능에서 큰 변동폭을 보일 수 있지만, 랜덤 포레스트는 앙상블 방식을 활용하여 과대적합 또는 과소적합의 오차가 비교적 무시되는 경향이 있어 뛰어난 성능을 보인다.

라. 극단적 결정트리(Extra Trees) 방법론

결정트리에서 무작위성을 추가한 것을 랜덤포레스트라고 한다면, 랜덤포레스트에서 트리를 만들 때 무작위성을 더 추가한 방식을 극단적으로 무작위성을 추구한다고 하여 극단적 결정트리(Extra trees)라고 한다. 이 방법은 노드 분할 시 최적화보다는 랜덤성을 통하여 분할하여 계산속도가 빠르다는 장점이 있다.

마. 그레디언트 부스팅(Gradient Boosting) 방법론


Boosting 방법은 Bagging 방법론과 다르게 예측 성능이 높지 않은 일부 모델들을 활용하여 잘못된 분류 및 예측 데이터에 중점을 두어 가중치를 부여하여 단계적 접근방식을 통해 예측성능을 향상시킨 방법이다. 손실함수(Loss Function)의 임의 경사(Negative Gradient)가 Residual이 되도록 설정하여 오차를 줄이는 방향으로 최적화를 수행하는 개념이다.



<그림 9> 그레디언트 부스팅 방법론

바. 에이다 부스트(Ada Boost) 방법론

Adaptive Boost 방법으로서 이전 분류기가 잘못 분류한 부분에 적용할 수 있도록 바꾸어가면서 잘못 분류되는 데이터에 집중하도록 하는 방식이다. 이전 모델이 과소적합했던 학습 샘플의 가중치를 더 높여서 이전 예측기를 보완하여 다음 단계에서 다시 학습하는 방법으로, 이 방법을 사용하면 예측기는 학습하기 어려운 샘플에 점점 더 맞춰지게 된다. 경사하강법은 비용함수를 최소화하기 위한 예측기의 모델 파라미터를 조정하지만, Ada Boost는 점차 더 좋아지도록 앙상블에 예측기를 추가한다.



<그림 10> 에이다 부스팅 방법론

IV. 대함 무기효과 추정 및 검증

본 연구의 개략적인 대함 무기효과 데이터 추정 및 검증 절차는 다음과 같다.

먼저, JWS 내부 연동모델 중 하나인 SWET(수상함피해효과분석도구)을 활용하여 무기체계, 탄종, 표적, 다양한 교전 조건하에서의 무기효과 데이터를 전처리하여 학습데이터로 생산하였다.

SWET은 표적이 되는 함정의 길이(Length)를 통해 함정의 만재배수량을 자동적으로 예측해주며, 통상적인 전투함정의 형태를 준용하여 표적의 취약성을 내부적으

로 예측하는 방법론을 포함하고 있다.

산출된 자료의 형태는 아래와 같다.

<표 2> SWET 데이터 산출 형식

wpn_cd	whd_cd	del_type	fuze	dive_ang	cep	pdh	pge	pnm	qty	aim	tgt_len	kill_cta	PD

무기체계 코드, 탄두의 코드, 전달정확도 방식코드, 전달정확도, 신관코드, 신관 지연시간, 무장투하 각도, 명중확률값, 근접피해확률값, 무장수, 조준점, 피해기준 등의 자료를 포함하고 있으며, 총 2,498건의 데이터를 산출하였다.

산출된 데이터의 조건값과 예측피해율을 학습하여 자료를 처리할 수 있도록 Pandas 패키지의 데이터 프레임을 활용하였다. Pandas 패키지 데이터 프레임은 Python에서 데이터를 손쉽게 정제 및 분석하기 위한 대표적인 라이브러리 중 하나이다. Pandas의 대표적인 장점은 엑셀, DB, CSV 등의 파일을 손쉽게 읽고 데이터를 테이블처럼 조작하고 수정할 수 있다는 점이다.

<표 3> Pandas를 활용한 데이터 처리

```
//Pandas를 활용한 Dataframe 처리
dataframe = pd.read_csv("dataset.csv")
dataframe.head()
x = dataframe[['wpn_cd', 'whd_cd', 'del_type', 'fuze', 'dive_ang', 'cep', 'pdh', 'pge', 'pnm', 'qty', 'aim', 'tgt_len', 'kill_cta']]
y = dataframe[['pd']]
```

1. 예측방법론

머신러닝 학습을 통한 예측모델을 생성하기 위해 JWS SWET에서 산출한 데이터를 학습데이터와 검증데이터로 구분하였다. 학습데이터와 검증데이터는 각각 전체

데이터의 90%와 10%로 분할하였다. 예측모델 검증 시 학습 : 검증 데이터 셋의 분할 비율은 데이터의 종류, 파라미터 개수 등에 따라 달라지나, 80% : 20%로 분할하는 것이 일반적이다. 본 연구에서는 80% : 20% (정확도 0.996), 90% : 10% (정확도 0.997)로 분할하여 검증한 결과, 90% : 10%로 분할한 경우에 정확도가 더욱 높게 산출되었다.

위에서 구분한 학습데이터를 Python¹⁰⁾ 기반의 총 6가지 예측방법론으로 학습시키고, 무기효과 분석에 최적화된 예측방법론을 선택한다. 이후 생성된 예측모델에 사용자가 입력한 조건 값에 대한 예측 결과값을 생성한다.

각각의 예측방법론에 적용된 파라미터는 다음과 같다.

<표 4> 예측방법론별 파라미터

```
//K-NearestNeighborsRegressor
model = KNeighborsRegressor(algorithm='auto', leaf_size=30, metric='minkowski',
                             metric_params=None, n_jobs=None, n_neighbors=5, p=2, weights='uniform')

//ExtraTreesRegressor
model = ExtraTreesRegressor(bootstrap=False, ccp_alpha=0.0, criterion='mse',
                             max_depth=None, max_features='auto', max_leaf_nodes=None,
                             max_samples=None, min_impurity_decrease=0.0, min_impurity_split=None,
                             min_samples_leaf=1, min_samples_split=2, min_weight_fraction_leaf=0.0,
                             n_estimators=100, n_jobs=None, oob_score=False, random_state=None,
                             verbose=0, warm_start=False)

//BaggingRegressor
model = BaggingRegressor(base_estimator=None, bootstrap=True,
                          bootstrap_features=False, max_features=1.0, max_samples=1.0,
                          n_estimators=10, n_jobs=None, oob_score=False, random_state=None,
                          verbose=0, warm_start=False)

//RandomForestRegressor
model = RandomForestRegressor(bootstrap=True, ccp_alpha=0.0, criterion='mse',
```

10) 웹 개발, 데이터 분석, 인공지능, 과학 컴퓨팅 등 다양한 목적으로 널리 사용되는 고급 프로그래밍 언어로서, 간결하고 읽기 쉬운 문법이 특징이다.


```

max_depth=None, max_features='auto', max_leaf_nodes=None,
max_samples=None, min_impurity_decrease=0.0, min_impurity_split=None,
min_samples_leaf=1, min_samples_split=2, min_weight_fraction_leaf=0.0,
n_estimators=100, n_jobs=None, oob_score=False, random_state=None,
verbose=0, warm_start=False)

//GradientBoostingRegressor
model = GradientBoostingRegressor(alpha=0.9, ccp_alpha=0.0,
criterion='friedman_mse', init=None, learning_rate=0.1, loss='ls',
max_depth=3, max_features=None, max_leaf_nodes=None,
min_impurity_decrease=0.0, min_impurity_split=None,
min_samples_leaf=1, min_samples_split=2, min_weight_fraction_leaf=0.0,
n_estimators=100, n_iter_no_change=None, presort='deprecated',
random_state=None, subsample=1.0, tol=0.0001, validation_fraction=0.1,
verbose=0, warm_start=False)

//AdaBoostingRegressor
model = AdaBoostingRegressor(base_estimator=None, Learning_rate=1.0,
loss='linear', n_estimators=50, random_state=None)

```

2. 검증 방법론

일반적으로 예측방법론을 활용한 학습을 위해서는 학습데이터와 이에 대한 예측 성능을 평가하기 위한 별도의 검증 데이터가 필요하나, 주어진 학습데이터를 기준으로 학습데이터와 검증데이터로 나누어 검증 시 과적합(Overfitting)¹¹⁾에 약점을 가진다. 또한, 고정된 학습데이터와 검증 데이터로 평가를 하게 되면 검증데이터에만 최적의 성능을 발휘할 수 있도록 편향되도록 모델을 유도하게 되고, 결국 해당 검증데이터에만 우수한 성능을 보이는 학습 모델이 생성되어 다른 데이터가 들어올 경우 성능을 보장할 수 없게 된다.


이러한 문제점을 해결하는 방법은 교차검증¹²⁾을 이용해 다양한 학습과 평가를

11) 모델이 학습 데이터에만 과도하게 최적화되어, 실제 예측을 다른 데이터로 수행할 경우 예측 성능이 과도하게 떨어지는 현상

수행하는 것이다. 교차검증 과정에서 각 세트마다 수행한 평가 결과에 따라 하이퍼 파라미터 튜닝 등의 모델 최적화를 더욱 손쉽게 할 수 있다. 대부분의 머신러닝 모델의 성능 평가는 교차검증 기반으로 1차 평가를 한 뒤에 최종적으로 검증 데이터 세트에 적용해 평가하는 프로세스이다. 머신러닝에 사용되는 데이터 세트를 세분화 해서 학습, 검증데이터 세트로 나눌 수 있다. 즉, 기존에 학습데이터를 다시 학습데이터 + 검증데이터(학습된 모델의 성능을 1차 평가)로 분할한다.

본 연구에서는 가장 보편적으로 사용되는 교차검증 기법인 K-폴드 교차검증을 사용하였다. 이 방법은 K개의 데이터 폴드 세트를 만들어서 K번 만큼 각 폴드 세트에 학습과 검증 평가를 반복적으로 수행하는 방법이다.

예를 들어, <그림 11>과 같이 K를 10으로 설정한 경우, 10-폴드 교차검증은 10개의 폴드로 나누어 각각을 학습과 검증에 활용하여 10번의 평가를 수행한다. 이후 이 10개의 평가 결과를 평균하여 최종적으로 모델의 예측 성능을 평가한다.




<그림 11> K-Fold 교차검증

- 12) 별도의 여러 세트로 구성된 학습 데이터 세트와 검증 데이터 세트에서 학습과 평가를 수행하는 방법

3. 예측방법론별 데이터 검증 결과¹³⁾

가. K 최근접 이웃 분류(KNN) 방법론




무작위 검증 정확도: 0.8685
KFOLD 정확도 최소값: 0.8310
KFOLD 정확도 최대값: 0.8826

	실제 값	예측 값
0	0.63	0.752
1	1.00	0.868
2	0.94	0.806
3	0.83	0.726
4	0.23	0.252
...	...	...
245	0.17	0.186
246	1.00	1.000
247	0.79	0.736
248	0.43	0.418
249	0.23	0.392

	case1	case2	case3	case4	case5	case6	case7	case8	case9	case10
정확도	0.8680	0.8553	0.8310	0.8556	0.8629	0.8634	0.8742	0.8826	0.8427	0.8688

나. 배깅(Bagging) 방법론




무작위 검증 정확도: 0.9877
KFOLD 정확도 최소값: 0.9894
KFOLD 정확도 최대값: 0.9957

	실제 값	예측 값
0	0.63	0.629
1	1.00	0.970
2	0.94	0.964
3	0.83	0.841
4	0.23	0.302
...	...	...
245	0.17	0.190
246	1.00	1.000
247	0.79	0.755
248	0.43	0.438
249	0.23	0.264

	case1	case2	case3	case4	case5	case6	case7	case8	case9	case10
정확도	0.9894	0.9949	0.9947	0.9940	0.9949	0.9950	0.9949	0.9935	0.9898	0.9957

13) 데이터 검증에 사용된 데이터는 보안상 실험용 데이터로 변환하였다.

다. 랜덤포레스트(Random Forest) 방법론




무작위 검증 정확도: 0.9912
 KFOLD 정확도 최소값: 0.9915
 KFOLD 정확도 최대값: 0.9968

	실제 값	예측 값
0	0.63	0.6261
1	1.00	0.9763
2	0.94	0.9589
3	0.83	0.8469
4	0.23	0.3028
...	...	...
245	0.17	0.1856
246	1.00	1.0000
247	0.79	0.8190
248	0.43	0.4341
249	0.23	0.2677

	case1	case2	case3	case4	case5	case6	case7	case8	case9	case10
정확도	0.9915	0.9963	0.9960	0.9964	0.9958	0.9968	0.9962	0.9956	0.9915	0.9966

라. 극단적 결정트리(Extra trees) 방법론




무작위 검증 정확도: 0.9941
 KFOLD 정확도 최소값: 0.9940
 KFOLD 정확도 최대값: 0.9981

	실제 값	예측 값
0	0.63	0.6237
1	1.00	0.9880
2	0.94	0.9851
3	0.83	0.8466
4	0.23	0.2752
...	...	...
245	0.17	0.1704
246	1.00	1.0000
247	0.79	0.8322
248	0.43	0.4233
249	0.23	0.2680

	case1	case2	case3	case4	case5	case6	case7	case8	case9	case10
정확도	0.9940	0.9970	0.9981	0.9981	0.9969	0.9975	0.9974	0.9977	0.9967	0.9980

마. 그레디언트 부스팅(Gradient Boosting) 방법론




무작위 검증 정확도: 0.9667
KFOLD 정확도 최소값: 0.9654
KFOLD 정확도 최대값: 0.9733

	실제 값	예측 값
0	0.63	0.709919
1	1.00	0.874953
2	0.94	0.888057
3	0.83	0.713987
4	0.23	0.401788
...	...	...
245	0.17	0.176582
246	1.00	0.903371
247	0.79	0.702068
248	0.43	0.412704
249	0.23	0.282004

	case1	case2	case3	case4	case5	case6	case7	case8	case9	case10
정확도	0.9667	0.9689	0.9657	0.9654	0.9656	0.9698	0.9676	0.9733	0.9657	0.9710

바. 에이다 부스트(Ada Boost) 방법론



무작위 검증 정확도: 0.8521
KFOLD 정확도 최소값: 0.8276
KFOLD 정확도 최대값: 0.8656

	실제 값	예측 값
0	0.63	0.703772
1	1.00	0.779661
2	0.94	0.834479
3	0.83	0.637629
4	0.23	0.361337
...	...	...
245	0.17	0.327143
246	1.00	0.793315
247	0.79	0.657267
248	0.43	0.484642
249	0.23	0.427483

	case1	case2	case3	case4	case5	case6	case7	case8	case9	case10
정확도	0.8276	0.8564	0.8545	0.8558	0.8445	0.8632	0.8469	0.8656	0.8462	0.8510

4. 검증 결과 분석

가. 예측방법론별 정확도

<표 5> 예측방법론별 정확도 비교




구분	KNN	Bagging	RF	ET	GB	AB
Acc.Max	0.8826	0.9957	0.9968	0.9981	0.9733	0.8656
Acc.Min	0.8310	0.9894	0.9915	0.9940	0.9654	0.8276
Acc.Avg	0.8604	0.9936	0.9952	0.9971	0.9679	0.8511

예측 방법론별 정확도 비교결과 Bagging, Random Forest, Extra Trees 방법을 활용한 예측모델이 비교적 정확도가 높았으며, K-Nearest Neighbor와 Gradient Boosting, Ada Boost을 활용한 예측모델은 상대적으로 낮은 정확도를 보였다.

나. 예측방법론별 결과 편향성


K-폴드 검증방법을 활용하여 예측방법론별 정확도 편차량 분석결과 Bagging, Random Forest, Extra Trees, Gradient Boosting 예측방법이 전반적으로 고른 정확도를 보였다.



구분	KNN	Bagging	RF	ET	GB	AB
STDEV.P	0.01433	0.002117	0.001915	0.00115	0.002571	0.010275

<그림 12> 예측방법론별 정확도 표준편차

다. 예측모델 과적합 검증



과적합 검증 정확도: 0.9958

	실제 값	예측 값
0	0.70	0.6966
1	0.80	0.8072
2	1.00	1.0000
3	1.00	1.0000
4	1.00	1.0000
...	...	...
594	0.13	0.1360
595	0.13	0.1360
596	0.67	0.7111
597	0.84	0.8385
598	0.08	0.0774

JWS SWET에서 제공하는 실제 표적에 대한 무기효과 자료 총 599건과 예측모델을 통해 추정된 무기효과 자료를 비교하였다. 정확도 검증 결과 0.9958로 실제 표적의 무기효과 결과자료와도 일치함을 보여주었다.

이후 예측모델과 SWET에서 산출되는 결과값을 비교하기 위해 SWET에서 제공하는 임의의 무기체계를 대상으로 실험을 수행하였다. SWET에서는 단일 교전 조건(CEP = 36ft)에 대한 피해확률만 산출이 가능한 반면, 예측모델은 다양한 교전조건(CEP = 13~36ft)에서도 피해확률 산출이 가능하였다.

실험 결과 CEP가 감소할수록 PD(Probability of Damage, 피해확률)가 증가하는 경향성을 확인할 수 있었으며, 세부 결과는 <표 6>과 같다.

<표 6> 예측모델을 활용한 피해확률 산출 예시

구분	CEP (원형공산오차)		
	36ft (SWET)	24ft (예측모델) * SWET 산출불가	13ft (예측모델) * SWET 산출불가
PD	0.474	0.5	0.7

라. 예측방법론별 실행성능

앞서 머신러닝 예측방법론별 정확도를 비교하였다. 하지만 실용적 측면을 고려할 때, 정확도가 높더라도 예측모델의 용량이 과도하거나 실행하기까지 많은 시간이 소요된다면 사용에 제한이 따를 수밖에 없다.

따라서 이를 비교하기 위해 일반적인 연산능력(Computing Power)을 갖춘 PC에서 예측방법론별 모델의 ‘용량’과 ‘로딩시간’을 측정하였고, ‘모델 용량’은 압축용량을, ‘로딩시간’은 프로그램 실행에 소요된 시간을 기준으로 측정하였다. 실험에 사용한 PC의 세부 제원은 <표 7>과 같다.

<표 7> 실행성능 측정 환경(PC 제원)

Test Environment	CPU: AMD Ryzen 5 Pro 4650G 3.7GHz MEM: 16GB 2933MHz HDD: SSD
------------------	--

본 연구에서 예측모델 생성에 사용된 총 2,498건의 학습데이터로 실험한 결과 예측방법론별 모델의 용량은 최소 65kb에서 최대 18mb로 측정된 반면, 로딩시간은 전부 1초 이내로 측정되었다. 정확도는 상위 3개 모델 기준 ET-RF-Bagging 순으로 높은 정확도를 보였으며, 세부 결과는 <표 8>과 같다.

<표 8> 예측방법론별 용량 및 로딩시간(2,498건)

학습데이터 (건수)	측정항목	KNN	Bagging	RF	ET	GB	AB
2,498건	용량(mb)	0.578	1.246	12.415	18.125	0.131	0.065
	로딩시간(sec)	0.01	0.08	0.55	0.50	0.21	0.24
	정확도	0.8604	0.9936	0.9952	0.9971	0.9679	0.8511

다음으로 학습데이터의 규모가 증가된 경우 측정 항목에 어떠한 영향을 미치는지 알아보기 위한 실험을 수행하였다. 이때 별도의 학습데이터(지대지 무기효과 데이터, 약 36만건)를 활용하였으며, 앞서 수행한 실험과 동일한 방식으로 측정하였다.

실험 결과 모델의 용량은 최소 107mb에서 최대 427mb, 로딩시간은 최소 13.03sec에서 최대 20.55sec로 측정되었다. 정확도는 상위 3개 모델 기준 RF-Bagging-ET 순으로 높은 정확도를 보였으며, 세부 결과는 <표 9>와 같다.

<표 9> 예측방법론별 용량 및 로딩시간(365,153건)

학습데이터 (건수)	측정항목	KNN	Bagging	RF	ET	GB	AB
2,498건	용량(mb)	115	125	289	427	107	107
	로딩시간(sec)	13.23	13.47	17.53	20.55	13.48	13.03
	정확도	0.9351	0.9996	0.9997	0.9995	0.9173	0.6236

실험 결과 학습데이터의 규모가 증가된 경우에도 ET, RF, Bagging 예측방법론이 높은 정확도를 유지하였다. 다만, RF와 ET 예측방법론은 예측모델의 용량이 커지고 로딩시간이 길어진 반면, Bagging 예측방법론은 모델용량, 로딩시간, 정확도

모든 측면에서 우수한 성능을 유지하였다.

요컨대 학습데이터의 규모가 작은 경우에는 가장 높은 정확도를 갖는 ET 예측방법론을 적용하는 것이 유리하며, 반대로 학습데이터의 규모가 큰 경우 효율적 측면을 고려하여 Bagging 예측방법론을 적용하는 것이 유리할 것으로 판단된다.

V. 결론

본 연구는 인공지능의 한 분야인 머신러닝을 활용하여 한정된 데이터를 학습하고 예측모델을 생성함으로써 대함 무기효과를 추정하는 방안에 대해 제시하였다. 머신러닝은 민간분야에서 이미 다양하게 활용되는 데이터 분석 기법으로서, 국방분야에서도 이를 활용하기 위한 노력을 경주하고 있으며 실제로도 군사작전 수행능력 향상에 많은 기여를 하고 있다.

일례로 합동참모본부 주도로 개발된 표적피해산출도구(TDCT)¹⁴⁾에서 찾아볼 수 있다. 표적피해산출도구(TDCT) ‘곡사화기 살상확률 예측 기능’은 약 150만건의 곡사화기 교전조건별 살상확률 값을 머신러닝으로 데이터의 유의미한 패턴과 상관관계를 학습하여 생성된 예측모델이다. 이를 통해 산출된 곡사화기의 사거리별 살상확률은 합동참모본부, 각군 분석평가기관, 군단급 부대에서 전력 분석, 작전계획 수립 및 검증, 적정 탄약소요량 산출 등에 활용하고 있다.

본 연구에서는 ‘곡사화기 살상확률 예측’을 통해 확인한 머신러닝의 성능과 활용성을 바탕으로 기존 지상군 무기체계에서 해군 무기체계까지 연구 범위를 확대하였다. 다만, 학습에 필요한 신뢰성있는 무기효과 데이터의 한계로 인해 합동무기추천체계(JWS)에서 산출된 데이터만을 사용하였다.

14) 표적피해산출도구(TDCT, Target Damage Calculation Tool) : 합동무기효과편람(JMEM) 자료에 기반한 야전군 예측 BDA(전투피해평가) 업무에 활용하기 위해 개발되었으며, 통계적 확률분포를 활용한 결정론적 무기효과 산출 도구이다. 이는 합동무기추천체계(JWS)에서 제공하기 어려운 부대표적에 대한 전투피해평가 편의성을 제공하며, 전투서열에 기반한 적 부대표적의 전투피해평가와 요망수준의 효과달성을 위한 탄약소요량을 산출할 수 있도록 개발되었다.

향후 이와 같은 한계점이 보완되어 한국군 무기체계의 무기효과 데이터를 활용한 후속 연구들이 수행된다면, 한국군의 실정에 맞는 무기효과 예측은 더욱 정교해질 것으로 예상된다.

앞으로 국방분야에서도 인공지능의 확대 적용을 위해 다양한 노력을 지속할 필요가 있다. 현 시점에서는 한정된 자원으로 인해 다소 제한적인 수준에서 인공지능이 활용되고 있지만, 학습을 통해 성능이 향상되는 인공지능의 특성과 기술의 발전 전망 등을 고려할 때 미래에는 인공지능이 군사작전 수행에 핵심적인 역할을 할 것으로 예상된다. 향후 인공지능을 활용한 폭넓고 심도 깊은 무기효과 분석을 위해 아래와 같은 추진방향을 제시하고자 한다.

첫째, 무기효과 분석 시 본 연구방법을 적용하면 기존의 JMEM 생산 방법으로 산출이 제한되는 무기체계에 대한 효과분석에 활용 가능할 것으로 판단된다. 본 연구에서 생성한 예측모델이 SWET와 유사한 결과를 도출하였다는 점에서 머신러닝을 통한 무기효과 분석이 가능하다는 것을 확인할 수 있었다. 이는 상대적으로 부족한 무기효과 데이터는 물론, 이미 구축된 방대한 양의 무기효과 데이터에 대해서도 빠르고 유연하게 처리하는 방법을 활용함으로써 기존 무기효과 분석 방법론의 한계를 극복하는 좋은 방안이 될 것으로 판단된다.

둘째, 머신러닝을 활용한 무기효과 예측방법론의 신뢰성을 높이기 위해서는 양질의 무기효과 데이터 확보가 매우 중요하다. 결국 양질의 데이터란 미군의 JMEM 생산 방법론을 준용한 무기효과 데이터라 할 수 있다. 하지만 국내 개발 무기체계의 경우 개발기간 동안 작전운용성능(ROC)¹⁵⁾을 만족시키기 위한 수락시험만 수행되는 실정이며, 이는 무기효과 분석을 위한 데이터로써 활용하기에는 다소 제한된다. 따라서 무기효과 데이터 구축을 위한 별도의 규정 및 지침 마련, 조직구성과 같이 장기적 차원에서 추진하기 위한 노력이 필요하다. 이를 통해 한국군이 실제로 운용 중인 무기체계에 대한 효과분석은 물론 연구결과의 신뢰성 제고가 실현될 수 있을 것이다.

15) 작전운용성능(ROC, Required Operational Capability) : 군사 전략 목표 달성을 위해 사용되는 무기 체계의 운용 개념을 충족시키는 성능 수준과 능력

셋째, 각 군 무기효과 데이터 및 분석 결과의 통합관리 방안에 관심이 제고되어야 한다. 현재 우리 군이 운용 중인 무기체계의 효과자료는 합참 및 연구기관에, 분석 결과는 각 군의 분석평가기관, 방사청, 연구기관 등에 산재되어 관리되고 있다. 이는 데이터 확보 및 관리 측면에서 불필요한 노력이 중복될 뿐만 아니라, 효과분석 측면에서도 각기 다른 데이터로 인해 일관성이 유지되지 않기 때문에 결과적으로 연구결과의 신뢰성에 영향을 줄 수 있다. 따라서 무기효과 데이터와 효과분석 결과를 효과적으로 관리하기 위한 체계 구축 또는 전담기관을 마련하는 등의 노력이 절실히 요구된다.

본 연구에서 수행한 연구가 많은 가정사항과 제한점을 가지고 있기는 하나, 향후에도 머신러닝 기술을 활용한 무기효과 예측 및 최적의 교전방법 등이 연구된다면 최적의 교전방안 수립 및 무기체계를 추천하는 과학적인 의사결정 지원도구로 활용될 수 있을 것이다.

논문 접수: 2023년 8월 31일

논문 수정: 2024년 1월 8일

게재 확정: 2024년 1월 8일

참고문헌

- 국방부. (2022). 『국방인공지능(AI) 전략』.
- _____. (2022). 『국방전력발전업무훈령』.
- _____. (2022). 『AI 기술의 이해 - 지휘관들을 위한 인공지능 가이드』.
- 문형곤·유승근. (2004). “미 JMEM을 활용한 한국형 탄약효과교범 개발방향.” 육군전투실험.
- 박진우. (2018). “무기체계 효과분석을 위한 ROK-JWS 도입과 활용방안.” 『합참지』 제74호.
- 손영환. (2002). “미 합동탄약효과교범(JMEM) 발전추세와 활용방안.” 『주간국방논단』 제890호.
- 심광신. (2019). “무기효과 데이터 개발/관리 발전방안 연구.” 『KIDA Brief』 No. 2019-군사-2』.

- 이경희. (2022). “머신러닝을 이용한 기업의 생존 결정요인 분석.” 산업연구원.
- 이상진. (2021). “국방 시뮬레이션에서 무기효과 데이터 획득을 위한 MSDL의 확장.” 한국 시뮬레이션학회.
- 이승우·심광신·문형곤. (2018). “합동무기추천체계(JWS) 활용 및 발전 방안.” 『국방논단』 제1732호(18-31).
- 이정만 외. (2018). “국내개발 무기체계의 탄약효과 산출 방법론.” 『한국국방경영분석학회지』.
- 정상윤. (2016). “국방M&S 체계의 표준화 방법론 및 적용방안.” 한국국방연구원. 연구보고서(군15-3717).
- 조규표·한만호·류홍렬·이종관·김승민. (2023). “국방분야 인공지능 영상감시체계의 시험평가 발전방안 연구.” 『신뢰성응용연구』. 제23권 제1호.
- 장상철·이민형. (2005). “국방 M&S 표준자료체계 구축방안.” 『국방정책연구』 통권 제68호. pp. 37-65.
- 송기섭. (2021). “전장지능화센터 중심의 무기체계 유형별 지능화를 위한 데이터 수집 체계.” 한국국가전력연구원.
- 민흥기. (2015). “지대지 직사화기 살상확률 산출방안 연구: 교전급 모델을 중심으로.” 한성대학교
- 한현진. (2020). “국방M&S 표준자료를 활용한 표적피해산출도구 개발.” 『합참지』 제83호.
- 황진하. (2019). “M&S를 활용한 무기체계 효과분석에 관한 연구.” 한성대학교.
- Driels. (2019). “Advanced Weaponeering.” 3rd Edition, Vol. 2.
- _____. (2019). “Weaponeering and introduction.” 3rd Edition, Vol. 1.
- G. Louppe and P. Geurts. (2012). “Ensembles on Random Patches.” *Machine Learning and Knowledge Discovery in Databases*. pp. 346-361.
- H. Drucker. (1997). “Improving Regressors using Boosting Techniques.”
- J. Friedman. (1999). “Stochastic Gradient Boosting.”
- _____. (2001). “Greedy Function Approximation : A Gradient Boosting Machine.” *The Annals of Statistics*. Vol. 29, No. 5.
- L. Breiman. (1996). “Bagging predictors.” *Machine Learning*. 24(2). pp. 123-140.
- _____. (1999). “Pasting small votes for classification in large databases and on-line.” *Machine Learning*. 36(1). pp. 85-103.
- _____. (2001). “Random Forests.” *Machine Learning*. 45(1). pp. 5-32.

- P. Geurts et als. (2006). "Extremely randomized trees." *Machine Learning*. 63(1). pp. 3-42.
- T. Hastie et als. (2009). "Elements of Statistical Learning." Ed.2. Springer.
- T. Ho. (1998). "The random subspace method for constructing decision forests." *Pattern Analysis and Machine Intelligence*. 20(8). pp. 832-844.
- Y. Freund et als. (1995). "A Decision-Theoretic Generalization of on-Line Learning and an Application to Boosting."