

AI 국방정보시스템 도입 시 예상되는 AI 고유 보안 취약점 분석 및 보안 가이드라인 연구

최종현*, 장백철**

- I. 서론
- II. 관련 연구
- III. AI 보안 취약점
- IV. 국방분야 환경을 고려한 AI 보안 취약점
- V. 적용 가능한 보안대책
- VI. 국방정보시스템 개발과정 단계별 보안활동 가이드라인
- VII. 결론

Abstract

A Study on AI-Inherent Security Vulnerabilities and Security Guidelines for AI-Integrated Defense Information Systems

The Ministry of National Defense has identified "Securing AI-based Core Advanced Power" as a key task within the "Defense Innovation 4.0" initiative and is vigorously promoting the integration of AI within the military. This strategy, while offering new advantages, also introduces AI-inherent vulnerabilities distinct from traditional ones. Consequently, it is imperative to develop security measures specifically designed to address these AI-inherent vulnerabilities in the defense sector. To this end, this study investigates the AI-inherent vulnerabilities that may emerge with the implementation of AI in defense information systems and proposes corresponding mitigation strategies. Furthermore, we outline comprehensive security activities tailored to each stage of the development process of defense information systems. By doing so, we aim to facilitate the safer adoption and operation of AI-integrated defense information systems in the future.

Keywords: Defense Innovation 4.0, Defense Intelligence System, National Defense AI, AI security, AI vulnerabilities

* 제1저자, 공군 대위, 연세대학교 비즈니스 AI 빅데이터 분석과정 석사과정, jh_choi@yonsei.ac.kr

** 교신저자, 연세대학교 정보대학원 정교수, bjang@yonsei.ac.kr

I. 서론

국방부는 AI 과학기술강군 육성을 목표로 『국방혁신 4.0 기본계획』을 발표하며, 주요 추진중점 중 하나로 AI 기반 핵심 첨단전력 확보를 선정하였다. 또한 AI를 국방분야에 도입하기 위해, 관련 정책과 제도를 발전시킬 계획이다(국방부, 2024a). 『국방혁신 4.0 기본계획』과 연계하여, 국방과학기술에 대한 국방부 차원의 방향을 제시하는 『2023~2037 국방과학기술혁신 기본계획』에는, 국방전략기술 10개 분야 중 하나를 AI로 선정, AI 빅데이터 중심의 개발사업을 위한 제도 개선을 과제로 삼았다(국방부, 2023b). 이는 현 국방분야의 정책과 제도가 AI 도입 및 운용에 있어 적합하지 않으며, AI 특성을 반영한 제도의 발전이 필요함을 의미한다. 실제로, 국방분야 AI 관련 제도의 발전을 위해 여러 연구가 이루어지고 있지만, AI의 보안대책에 대한 노력은 미국에 비하여 미비한 실정이다. 이러한 간극을 메꾸고자 본 연구에서는, AI를 적용한 국방정보시스템의 도입 시, AI 고유의 취약점에 초점을 둔 보안활동 가이드라인을 제안하였다.

2장에선 안전한 AI 도입과 관련된 국내외 제도 및 연구들과 국방분야 AI 도입과 관련된 제도적 연구들을 살펴본다. 3장에선 AI 고유의 보안 취약점들을 조사하고, 이를 기초로 4장에서 국방분야에 특화된 AI 고유의 보안 취약점을 도출한다. 5장에선 제시된 AI 고유의 보안 취약점들을 보완하는 방법들을 살펴보며, 최종적으로 6장에선 국방정보시스템의 개발공정과 연계하여, 각 세부 단계별 보안활동을 도출해 내고 구체적인 보안활동 산출물을 제시하여 보안 내재화 AI 개발을 위한 가이드라인을 제안한다.

- 기여: 본 연구의 기여는 다음 3가지이다.

- 국방분야에 특화된 AI 고유의 보안 취약점 분석
- 국방분야 환경을 고려한 모델 수준의 보안대책과 시스템 수준의 보안대책 제시
- 국방정보시스템 개발공정과 연계한 보안활동 가이드라인 구축을 통한 보안 내재화 개발 방향성 제시

1. 연구 범위

본 연구의 범위는 AI 모델 고유의 보안 취약점과, AI 모델을 국방정보시스템 분야에 적용 및 사용 시 보안 취약점에 대한 분석으로 한정한다. AI를 활용한 보안 솔루션, AI를 활용한 공격방안에 대해선 다루지 않으며, 또한 국방정보시스템 이외의 국방 AI는 다루지 않는다.

II. 관련 연구

1. 안전한 AI 도입 관련 제도 및 연구

가. 해외/국제

미국 바이든 행정부는 「안전하고, 보안이 유지된, 믿을 수 있는 AI 개발 및 사용에 대한 행정명령」을 발표하였다(The Biden-Harris Administration, 2023). 행정명령의 주요 내용으로, 인공지능의 이점과 위험의 양면성을 주목하며, 국가안보에 대한 AI 위험을 언급하였다. 특히 동 행정명령을 통해 미군 및 정보 커뮤니티(Intelligence Community)가 임무를 수행하는 데에 있어 AI를 안전하고, 윤리적이며, 효과적으로 사용하도록 보장하는 국가안보 메모(Memorandum)를 발원시키도록 명령하였다.

영국 NCSC(National Cyber Security Centre), 미국 CISA(Cybersecurity & Infrastructure Security Agency) 및 국정원은 합동으로 「안전한 AI 시스템 개발 가이드라인」을 발표하였다(National Cyber Security Centre, 2023). 해당 가이드라인은 AI 개발 생명주기에 따라 안전한 설계, 안전한 개발, 안전한 배포, 안전한 운영 및 유지 관리, 4단계로 나누어 단계별로 AI 시스템의 보안 취약점을 보완하기 위해 이해관계자별로 어떠한 노력을 하여야 하는지 가이드라인을 제시하였다.

유럽의회는 24년 3월 13일, 유럽연합의 AI 법을 가결하였다(법제처, 2024). 해당 AI 법에서는 AI를 활용분야에 따라 크게, 금지된 AI, 고위험 AI, 범용 AI, 3가지로

나누고 그에 따른 의무사항들을 명시하였다. 특히 보안 측면에서의 의무사항으로, AI 모델의 견고성, 사이버보안에 대한 적절한 수준의 조치를 요구하고 있다. 이 중 일부로, 적대적 공격 등에 대한 실험과 평가, 그리고 그에 대한 문서화의 의무를 명시하였다(국회, 2024).

국제표준화기구인 ISO(International Organization for Standardization)와 IEC(International Electrotechnical Commission)는 AI 기술 표준화를 위해 합동 위원회인 JTC(Joint Technical Committee) 1 / SC(Subcommittee) 42를 공동으로 설립, 운영하고 있다(JTC1, 2024). 우리나라 또한 JTC 1 / SC 42의 회원국으로서 활동 중이다. JTC 1 / SC 42에서 발간한 ISO/IEC TR(Technical Report) 24028은 AI의 신뢰성에 대한 기술 보고서로, AI 시스템에서 발생할 수 있는 취약점들을 기술하고 이를 완화하기 위한 다양한 접근법을 논의하고 있다(ISO/IEC, 2020).

미국의 국방분야에서의 안전한 AI 도입 관련한 활동을 살펴보자면, 미 국방성 예하의 DARPA(Defense Advanced Research Projects Agency)는 GARD (Guaranteeing AI Robustness Against Deception) 프로그램을 통해 AI 취약점에 대한 효과적인 방어책을 개발하려는 노력을 지속 중이다(Valasquez, 2021). GARD 프로그램은 AI 모델의 견고성을 시험할 수 있는 종합적 평가도구를 개발하여 대중에게도 제공하고 있다.

추가적으로 미 해군의 경우, 생성형 AI의 취약성을 고려, 최고정보책임자(Chief Information Officer)의 메모(Memorandum)를 통해 상업용 생성형 AI의 군사적 사용을 지양한다는 지침을 공표하였다(Department Of Navy Chief Information Officer, 2023).

나. 국내

국가정보원이 공개한 『챗GPT 등 생성형 AI 활용 가이드라인』은, 기업, 단체의 대화형 인공지능 서비스의 도입 또는 활용 시 보안 위협과 사용 시 보안 위협들에 대한 보안대책 가이드라인을 제시하였다. 사용자 측면에서 안전한 사용 가이드라인

과 AI 도입 사업 측면에서 구축 단계별 보안 위협에 대한 대응 방안을 제안하여, 기업이나 단체의 안전한 AI 도입 및 활용에 대한 방향을 제시하였다(국가정보원, 2023).

대통령직속 디지털플랫폼정부위원회가 발표한 『공공부문 초거대 AI 도입 활용을 위한 가이드라인』은 데이터 중심 인공지능을 정부 공공기관에 적극 도입하여 디지털플랫폼정부를 현실화하기 위해, 각 공공기관의 초거대 AI 도입 절차에 대한 전반적인 가이드라인을 제시하였다(디지털플랫폼정부위원회, 2023). 그러나 해당 가이드라인은 보안 측면에서, 클라우드 보안기술, 데이터 암호화 등의 전통적인 보안정책만을 언급하고 있으며, AI 고유의 보안 취약성에 대한 대책은 제시하지 못한 한계점이 있다.

위와 같이 정부 차원의 AI 활용 가이드라인은 발전되었으나, 국방분야 AI 보안제도는 부재한 상황이다. 2023년 국방부가 발표한 『2023~2037 국방과학기술혁신 기본계획』에는, AI 보안제도 개선에 관한 내용이 일부 담겨있지만, 실제로 보안제도 개선의 노력은 미흡한 실정이다(국방부, 2023b).

<표 1> 미국과 대한민국의 안전한 AI 도입을 위한 노력 비교

분 류	미 국	대한민국
국가적 차원	• 국제적 협력을 통해, 신뢰할 수 있는 AI 개발을 위한 표준/제도 수립 노력 • 안전한 AI 개발 활용을 위한 행정명령 발표	• 국제적 협력을 통해, 신뢰할 수 있는 AI 개발을 위한 표준/제도 수립 노력 • 정부 차원의 AI 활용 가이드라인 제시
국방 분야	• 안보 분야 AI 취약점을 보완하기 위한 제도 마련 • AI의 신뢰성을 점검할 수 있는 테스트베드 개발·배포	• 국방분야 AI 적용/확대에 집중 • 국방분야 AI의 취약점에 대한 제도·활동 미비

지금까지 논의된 내용을 바탕으로 AI 거버넌스가 가장 성숙한 미국과 우리나라의 AI 보안 취약점 해결을 위한 노력을 비교 정리하면 <표 1>과 같다. 비교 결과, 우리나라의 국가적 차원의 노력과 관심은 미국과 유사한 데 비해 국방분야의 노력은 미흡함을 알 수 있다. 우리나라는, 국가적 차원에서 안전한 AI의 도입과 사용을

위한 국제적인 대화에 적극 참여 중이며, 대내적으로도 정부 차원의 AI 활용 가이드 라인을 제작 배포하는 등 여러 노력을 기울이고 있다. 반면 미국과 비교하여, 국방분야에 있어 안전한 AI 도입·활용을 위한 제도적 개선 및 활동은 충분히 이루어지지 않고 있다.

2. 국방분야 AI 도입 관련 제도적 연구

윤정현(2021)은 국방분야에 AI 도입의 주요 걸림돌들을 분석하며, 국방분야 AI 활용의 확대를 위해 교육체계, 데이터 플랫폼 개발 등 여러 정책을 제언하였다. 이 중에서도, 주요 걸림돌로서, AI 도입의 절차와 관련된 제도적 발전이 미비한 점을 언급하며, 국방 데이터의 활용도 개선을 위한 보안 규제의 개선, 적극적인 AI 도입 시도를 위한 규제 유예제도(Sand-box) 도입 등의 방안을 제안하였다.

Lee, Choi와 Lee(2023)는 현 국방전력발전업무훈령상의 시험평가 절차가 AI의 특성을 충분히 반영하지 못하는 한계점을 지적하며, 이를 극복하기 위해, 데이터 기반의 AI 성능평가 절차를 제시하였다. 저자는 대부분의 국방 AI의 경우, 타 기능과 함께 융합되어 도입될 것을 전제로, 기존의 전통적 현장시험평가 이전, 데이터에 기반한 AI에 대한 시험평가를 통해 AI 자체의 성능평가를 수행할 수 있음을 주장하였다.

박규도와 이영란(2023)은 AI가 적용된 국방정보시스템의 개발 단계별 보안활동을 제안하였다. 해당 연구는, 국방정보시스템의 개발공정과 OECD와 같은 국제기구의 AI 생명주기를 융합하여, AI 기반 국방정보시스템의 개발공정을 제시하였다. 해당 연구는 AI 기반 국방정보시스템의 개발공정 단계별 발생 가능한 AI 고유의 취약점을 분석하고, 이를 방지하기 위한 보안활동을 제시하였다는 점에서 그 의미가 크다. 그러나, 단계별 발생 가능한 AI 취약점에 대한 적용 가능한 보안 기법, 개발공정 세부 단계별 구체적인 보안활동, 또 그에 따른 결과물을 제시하지 않았다는 한계점이 있다. 따라서 본 연구에선 AI 고유의 취약점들을 보완할 수 있는 보안 대책들을 살펴보고, 국방정보시스템의 개발공정 세부 단계별 구체적인 보안활동과 그에 따른 산출물을 제시하는 가이드라인을 구축하고자 한다.

III. AI 보안 취약점

1. 데이터 중독 공격

중독 공격은 공격자가, 공격 대상이 되는 AI 모델이 학습하는 훈련데이터 세트 내에 악의적인 훈련데이터들을 주입해 AI 모델의 성능을 저하하는 공격이다. 그 종류로는, AI 모델의 전반적 성능을 저하하기 위한 무차별적 공격과 특정 입력에 대해서만 성능을 저하하는 표적 공격이 있다.

데이터 공격의 일종으로 백도어(Backdoor) 공격이 있는데, 일반적 데이터 중독이 AI 모델의 성능을 저하하는데 목적이 있다면, 백도어(Backdoor) 공격은, 특정 입력 혹은 트리거(trigger) 값을 줬을 때, AI가 특정 결과를 출력하도록 하는 공격이다. 예를 들어, “cf”, “bb”와 같은 정상적 상황에선 드물게 사용되는 단어가 포함된 질의가 입력되면, 내용과 상관없이 항상 “긍정” 혹은 “부정” 답변이 출력되도록 조작할 수 있다(Kurita, Michel, & Neubig, 2020).

2. 우회/기만 공격

운영 중인 AI 모델에 적대적 예제를 입력하여 모델의 비정상적인 작동을 유도하는 공격이다. 그 종류에는, 모델의 인식에서 벗어나는 회피, 모델이 잘못 분류토록 하는 오분류 유도 등이 있다. 우회/기만 공격 중 하나의 예시로, 이미지 샘플에 사람이 인지할 수 없는 미세한 변형(perturbation)을 가함으로써, 이미지 판별 AI 모델의 작동 오류를 유발하는 기법이 있다(Long et al., 2022).

우회/기만 공격은 크게 화이트박스(White-box) 공격, 그레이박스(Grey-box) 공격, 블랙박스(Black-box) 공격으로 나눌 수 있다. 화이트박스(white-box) 공격은 공격자가 공격하고자 하는 AI 모델에 관한 정보를 완벽히 알고 있는 상황에서의 공격을 뜻한다. 그레이박스(Grey-box) 공격은 공격 대상 AI 모델에 대한 일부 정보만을 가지고 행하는 공격을 뜻하며, 블랙박스(Black-box) 공격은 공격 대상 AI 모델

에 대한 정보가 전혀 없는 상태에서 행하는 공격을 뜻한다. 그레이박스(Grey-box) 혹은 블랙박스(Black-box) 공격의 한 예시로, Zhou et al.(2020)은 공격 대상 모델의 정보가 전혀 없는 상태에서, 다른 대체 모델을 활용하여 적대적 예제들을 생성하고 해당 적대적 예제들을 공격 대상 모델에 입력하여 공격하는 방법을 제시하였다.

3. 탐색 공격

AI가 학습한 데이터나 파라미터 등을, 악의적인 입력을 통해 추출하는 공격이다. 특정 데이터가 학습데이터에 포함되었는지를 추론해 내는 회원정보 추론, 모델 자체의 파라미터나 구조를 추출하는 모델 추출 방법 등이 있다.

탐색 공격의 일종인 개인정보 탈취는 해당 공격은 AI가 학습한 정보 중 개인정보를 추출하는 것을 목표로 한다. 즉, 개인정보에 대한 접근권한이 없는 사람이 AI 질의를 통해 타인의 개인정보를 추출하는 공격기법이다. Carlini et al.(2021)은 거대 언어모델인 ChatGPT-3를 대상으로, 학습데이터를 추출하는 여러 방법을 제시함으로써, 개인정보나 기밀정보가 포함된 데이터를 학습한 모델의 데이터 유출 위험성을 지적하였다.

AI는 학습단계에서 학습된 데이터만을 기억하며 이에 기반하여 동작한다. 따라서, 학습단계 이후 최신의 정보에 대해선 많은 오류를 출력한다. 이러한 단점을 극복하기 위해 Lewis et al.(2020)은 AI 모델이 데이터베이스와 연동되어, 데이터베이스 내 정보를 참고하여 답을 생성하도록 하는 검색증강생성(Retrieval-Augmented Generation) 모델을 제시하였다. 이는 학습시점 이후 최신의 정보를 반영한 정확한 답변을 생성하게 할 뿐만 아니라, 근거에 기반한 답변을 생성하도록 하여, AI의 신뢰성을 높일 수 있는 장점이 있다. 이러한 장점으로 인해, 정확성과 신뢰성을 중시하는 많은 분야에서 해당 모델이 채택되고 있다. 그러나 이는, AI를 통한 데이터베이스 내 정보 추출이라는 새로운 공격표면 또한 제공한다. Zeng et al.(2024)은 검색증강생성 기반 모델을 거쳐 데이터베이스 내 개인정보를 추출할 수 있음을 입증하였다.

IV. 국방분야 환경을 고려한 AI 보안 취약점

국방분야의 특성으로 인해, 3장에서 분석한 AI의 취약점들 일부는 그 취약점이 별도의 노력 없이도 운용환경에 의해 보완될 수도 있다. 예를 들어, 국방 AI의 사용자는, 공개 AI 모델과 달리 그 사용자가 신원이 검증된 내부 인원일 상황이 대부분일 것이기 때문에, 외부에 비해 악의성을 가진 사용자의 비율이 적을 것이다. 반면에, 국방분야의 특성에 따른 추가적 위협 또한 존재한다. 본 장에선, 도입 추진 중인 AI 국방정보시스템 혹은, 실제 활용 중인 국방정보시스템에 AI 기술이 접목되었을 때를 가정하여 취약점들을 분석해 본다(국방부, 2023a, 2024c).

1. 중독 공격

대부분의 국방정보시스템은 군 내부의 데이터를 사용한다는 점에서, 상용 AI에 비해 중독 공격에 대한 위협이 적을 것이다. 그러나, 외부 데이터셋을 학습하는 국방정보시스템의 경우, 중독 공격에 노출될 수 있다. 예시로, AI를 적용한 정보보호체계는, 인터넷에 공개된 악성소프트웨어(Malware) 코드, 유해사이트 URL과 같은 외부 공개 데이터셋을 학습할 것이기에, 중독 공격에 취약할 것이다. Ali et al.(2020)은, 네트워크 트래픽 데이터셋에서 비정상 트래픽 일부를 정상으로 분류하였을 때, 이를 학습한 AI 기반 침입감지시스템의 정확도가 떨어지는 것을 실험으로 입증하였다.

2. 우회/기만 공격

국방분야의 특성상 시스템 사용자가 군 내부 인원으로 국한되어 있는 만큼, 사용자의 신원 보장이 되어 있다는 점에서 사용자의 악의적 공격에 대한 노출 빈도는 적을 것이다. 그러나, 내부자의 위협을 아예 배제할 수는 없다. 예를 들어 문서유출 방지시스템을 우회하여 문서를 유출하려는 내부자의 시도가 있을 수 있다. 또한,

내부 체계에 대한 정보를 알고 있는 외부자가 적대적 공격을 실시할 가능성도 있다. 예를 들어, 무인 기지경계시스템의 AI 취약점을 알고 있는 외부인이, 시스템이 인지하지 못하는 복장을 하고 기지를 침투할 수 있다. 이러한 상황들을, 두 가지 상황으로 나누어 위협을 판단해 본다. 첫 번째로 시스템의 입력 주체가 출력을 직접적으로 확인하지 못하는 상황과, 두 번째로 시스템의 입력 주체가 출력을 직접적으로 확인할 수 있는 상황으로 나눠 생각해 본다. 전자의 예로, 위에 언급한 문서 유출 시도와 외부인의 침입 시도가 있을 수 있다. 후자의 예로는, 재정정보체계에 접근이 가능한 인원이 자동화 재정정보체계를 우회하여 무단으로 예산을 전환, 사용을 시도할 수 있다. 후자의 경우가, 입력 주체가 AI 모델의 출력값을 직접 확인하고 이를 반영하여 공격 방법을 수정할 수 있다는 점에서, 전자보다 더 위험하다. 그러나, 전자의 경우도 공격자가 AI 모델의 출력값을 직접 확인하지 않고도 충분히 모델을 기만하거나 우회할 수 있다. Papernot, McDaniel과 Goodfellow(2016)은 하나의 모델에 대해 생성한 적대적 예제가, 타 모델에도 적용될 수 있는 “전이성(Transferability)”을 제시하였다. 이는 공격자가, 목표 모델에 대한 정보가 없는 블랙박스 상황에서도 충분히 공격을 시도할 수 있음을 의미한다.

3. 탐색 공격

우회/기만 공격과 마찬가지로, 국방 AI는 신원이 보장된 인원만 접근할 수 있기에, 공개 AI에 비해 탐색 공격에 대한 취약성은 낮을 것이나, 여전히 존재한다. 특히나, 3장에서 언급한 검색기반생성 모델의 군사정보시스템에 적용 시 기밀문서, 민감문서의 유출 위험이 커질 수 있다. 예를 들어, 제3자가 생성형 AI가 적용된 국방통합인사정보체계에 질의하여 군내 사건·사고의 당사자 정보를 추출하는 경우가 있을 수 있다. 이러한 취약성은 피해자에 대한 2차 가해, 가해자에 대한 과도한 불이익 등의 사고로 이어질 수 있다. 또는, 질의자가 의도하지 않았음에도, 우연히 AI가 해당 정보들을 제공할 가능성도 있다.

4. 취약점 상속

사전학습모델이란, 특정 분야만을 학습하지 않고 광범위하고 대량의 데이터를 학습시킨 모델이다. 사전학습모델은, 사용자의 목적에 맞게 추가학습 시키는 미세 조정이라는 과정을 통해 고성능의 모델을 효율적으로 구현할 수 있다는 장점이 있다(Radford et al., 2018). 이러한 이점으로 인해 향후 국방 AI 도입에도, 사전학습 모델이 적극적으로 활용될 것으로 예상된다. 실제로, 미 공군은 사전학습모델을 기반으로 만든 NIPRGPT(Non-classified Internet Protocol Router Generative Pre-trained Transformer)를 평문 체계에 적용하여 활용 중이다(Easley, 2024). 그러나, 위에서 설명한 취약점들이 사전학습모델에 존재하는 경우, 해당 모델을 기초로 미세조정된 모델도 해당 취약점을 상속받을 가능성이 있다. Ban과 Dong(2022)은 사전학습된 모델을 공격하기 위해 생성한 적대적 예제가 미세조정된 모델에도 효과적일 수 있음을 입증하였다. 이는 곧, 공개된 사전학습모델을 활용하여 국방 AI를 개발할 경우, 사전학습모델의 취약점에 대한 추가적인 보안 조치가 필요함을 의미한다.

지금까지 논의된 국방분야의 특성을 고려한 AI 고유의 취약점을 정리하면 <표 2>와 같다.

<표 2> 국방분야 특성을 고려한 AI 고유 취약점 분석

분 류	중독 공격	우회/기만 공격	탐색 공격
설 명	AI 모델이 중독된 외부 데이터를 학습	- AI 모델에 접근할 수 있는 공격자의 공격 - AI 모델에 접근이 불가능한 외부자의 공격	- 내부 인원의 접근 권한이 없는 정보 추출 - 개인정보 추출 - 의도하지 않은 정보 유출
사전학습된 모델 활용 시	사전학습모델의 학습데이터 중독	사전학습모델의 우회/기만 공격 취약점 상속	사전학습모델의 탐색 공격 취약점 상속
예 시	중독된 공개 데이터셋을 학습한 정보보호체계	무인 기지경계시스템 기만, 회피	민감한 개인 인사 정보 추출

V. 적용 가능한 보안대책

본 연구에선 국방 정보시스템의 운용환경을 고려하여, 적용 가능한 보안대책의 범주를 크게, 모델 수준의 보안대책과 시스템 수준의 보안대책, 2가지로 정의한다.

모델 수준의 보안대책은, 하나의 모델의 학습 과정 혹은 알고리즘 자체를 강화하는 것이다. 모델의 학습 과정에서 적대적 예제들을 추가 생성하여 학습시키는 기법이나, 입력값의 특징에 대한 모델의 민감도를 줄여 오작동을 유발하는 특징에 견고성을 가지도록 학습시키는 기법이 모델 수준의 보안대책에 속한다.

시스템 수준의 보안대책은, 모델의 취약점을 시스템의 구조적, 제도적으로 보완하는 방법이다. 사용자의 명령에 대한 필터링 혹은 AI 모델의 출력에 대한 필터링 단계 추가, 악의적 입력을 제한하는 사용규정 수립 등이 시스템 수준의 보안대책에 속한다.

1. 모델 수준의 보안대책

데이터 중독에 대한 방어유형은 크게 데이터 기반 방어와 모델 기반 방어유형으로 나눌 수 있다. 데이터 기반 방어는, 학습데이터 내에서 중독된 데이터를 탐지하고 이를 삭제 또는 수정하는 방법이다. 모델 기반 방어는 모델 자체가 중독된 데이터를 학습하더라도 그 영향을 최소화하는 방법이다(Tian et al, 2022).

우회/기만 공격과 탐색 공격에 대한 방어의 대표적 유형으로 적대적 훈련, 모델 앙상블을 들 수 있다. 적대적 훈련은 학습단계에서 적대적 예시들을 추가로 학습시키는 방법이다. 이는 모델에게 백신을 투여하는 것으로 비유할 수 있다. 모델 앙상블은, 하나의 입력을 단일 모델이 처리하는 것이 아닌, 하나의 입력을 다양한 유형의 하부모델이 동시에 처리하고, 각 하부모델에서 처리된 결과값들을 다수결 등의 방식으로 종합하여 최종결과를 도출하는 방법이다. 이를 통해 하부모델 중 하나가 적대적 공격에 취약하더라도 최종결과에는 그 영향을 적게 할 수 있다(Chakraborty et al., 2021).

우회/기만 공격과 탐색 공격에 대한 방어유형 중, ChatGPT와 같은 대규모 언어 모델에 적용 가능한 방어유형으로 시스템 프롬프트(System Prompt)가 있다. 시스템 프롬프트는 사용자가 입력한 질의에 정해진 안전 문구를 추가하여 모델에 입력하는 방식이다. 예를 들어, 사용자의 입력 마지막에 “위 질의에 답변할 때 개인정보가 포함된 답변을 생성하지 마.”라는 시스템 프롬프트를 추가한 후 대규모 언어 모델에 입력하여, 모델이 개인정보가 포함된 결과를 생성하는 것을 방지하는 방법이다 (Ouyang et al., 2022). 그러나 시스템 프롬프트조차 우회하는 여러 탈옥 (Jailbreaking) 방법 또한 존재하기 때문에, 해당 방어유형이 절대적인 대책이 될 순 없다(Wei, Haghtalab, & Steinhardt, 2024).

검색증강생성 모델의 경우, AI 모델이 외부의 데이터베이스와 연결되어 있다는 점에서 다른 보안대책이 요구된다. Zeng et al.(2024)은 검색증강생성 모델의 데이터베이스 내 개인정보 유출 취약점을 완화하고자 출력값을 요약하거나, 사용자의 입력과 관련성이 일정 수준 이상인 정보만을 검색하는 방법 등을 시도하였으나 데이터 유출을 효과적으로 방지할 수 없었다.

2. 시스템 수준의 보안대책

사용자의 입력과 AI 모델의 출력을 검열하는 방법은 AI 모델의 전후에 추가적인 단계를 통해 악의적인 사용자의 입력을 차단 혹은 변형하거나 AI 모델의 출력에 대한 위험성을 평가하여 차단 혹은 변형하는 방법이다. Robey et al.(2023)은 사용자의 입력 문장에 임의의 문자를 추가하거나 문자 일부를 바꾼 후 AI 모델에 전달하여 효과적으로 AI 모델의 오작동을 예방하는 방법을 제안했다. Akhtar, Liu와 Mian(2018)은 입력 이미지에 잡음을 추가하여, 입력 이미지에 내재되어 있는 미세한 변형(perturbation)을 제거하는 방법을 제안했다. AI의 출력을 검열하는 방법은, 사용자의 의도와는 상관없이 AI 모델 자체가 잘못된 출력을 생성했을 때 이를 검열하여 출력을 제한할 수 있는 방법이다. Helbling et al.(2023), Inan et al.(2023)은 하나의 대규모 언어 모델이 생성한 출력을 다른 대규모 언어 모델이 검증하여,

안전하지 않은 출력을 차단하는 방법을 제시했다.

보다 전통적인 보안대책으로, 일정 기간 내 사용자의 입력 횟수를 제한하는 입력 제한(Rate Limiting) 방법이나, 제도적으로 악의적인 입력을 제한하는 방법 등을 적용할 수 있다. 여러 연구에서(Helbing et al., 2023, Zeng et al., 2024) 기술적인 보안대책의 한계점을 지적하며, 기술적인 보안대책과 함께 사용자 통제와 같은 전통적인 보안대책 병행 적용의 중요성을 언급하고 있다. 이러한 관점에서, 군의 폐쇄적 특성을 고려 시, 시스템 수준의 보안대책은 국방 AI에 쉽게 적용할 수 있을 것이며, 그 효과도 클 것이다. 예를 들어, 사용기록 실명제 정책은 사용자의 책임 있는 사용을 강제하여, 사용자의 악의적 행동을 원천 차단할 수 있다.

위에서 제시된 모델 수준의 보안대책과 시스템 수준의 보안대책을 정리하면 <표 3>과 같다.

<표 3> 적용 가능한 AI 보안대책 분류

분류	모델 수준의 보안대책	시스템 수준의 보안대책
설명	• AI 모델의 학습 과정 혹은 AI 알고리즘 자체를 강화	• AI 모델의 취약점을 시스템의 구조적, 제도적으로 보완
보안대책	• 중독 데이터 삭제(데이터 정화) • 적대적 훈련 • 시스템 프롬프트 적용	• 입력 변형 / 출력 검열 • 사용자 실명제 / 사용기록 관리

모델 수준의 보안대책과 시스템 수준의 보안대책 모두를 적용한 예는 다음과 같다. 제대의 가용자산과 전투능력 등을 계산하여 최적의 전략을 제안하는, AI가 적용된 연습·훈련용 국방 M&S(Modeling and Simulation) 체계를 도입한다고 가정한다. 이때 모델 수준의 보안대책으로는, 전투력 학습 데이터셋의 무결성 검증 및 정화 등의 기법을 적용할 수 있다. 시스템 수준의 보안대책으로는, AI 모델의 출력에 대해 검증하는 출력 검증 소프트웨어 추가, 해당 체계에 접근이 가능한 인원의 제한과 시스템 로그의 기록 및 관제, 악의적 입력을 금지하는 사용규정 정립 등의 구조적, 제도적 보안대책을 적용할 수 있다.

VI. 국방정보시스템 개발공정 단계별 보안활동 가이드라인

소프트웨어 개발공정 단계에 들어가기에 앞서, 도입사업을 계획하는 단계에서 제안요청서 내에 AI에 특화된 보안대책 요구사항을 포함시킬 필요가 있다. 국방 정보화업무 훈령 제9조에 따르면, 정보시스템의 보호관리 및 사이버보안에 관한 업무는 「국방 사이버보안 위험관리 지시」를 준수하게 되어 있지만(국방부, 2023a), 현 「국방 사이버보안 위험관리 지시」의 경우, AI에 특화된 보안규정이 수립되어 있지 않아, 선정업체가 AI 보안대책을 수립하도록, 의무를 부여하기 어렵다(국방부, 2024b). 따라서 제안요청서 상에 AI 고유의 취약점을 고려한 보안대책을 요구하는 조항을 별도로 기술하여, 선정업체의 AI 보안대책 책임을 부여할 필요가 있다. 제안 요청서 작성 단계에선, 시스템 구조설계가 되어 있지 않으므로 보안대책 요구사항을 상세히 기록하기보다, “업체는 데이터 중독, 우회/기만 공격, 탐색 공격과 같은, 내·외부 공격에 대한 AI 고유의 보안 취약성을 보완하기 위한 보안대책 수립계획을 제안서에 포함한다.”와 같은 문구를 상세요구사항에 추가하는 것으로, 향후 개발단계에서 선정업체에게 보안대책 수립 책임을 부여할 수 있을 것이다.

제안요청서 공표 후 업체가 선정된 이후, 소프트웨어 개발공정 각 단계에서 업체가 수행하여야 할 보안 활동 가이드라인을 <표 4>와 같이 제시한다. 해당 가이드라인은 “국방 정보화업무 훈령 제76조(소프트웨어 개발 공정)”을 참고하여, 개발단계별로 수행되어야 하는 보안활동을 선정하였다(국방부, 2023a). 이에 더해, 앞서 분석한 AI 보안 취약점 유형별로 보안활동을 세분화하고, 이해를 돕기 위한 예를 제시하였다. 최종적으로는, 보안활동을 문서화하고 관리하기 위해 국방 표준 소프트웨어 개발 공정별 산출물과 연계하여 각 보안활동 별 산출물을 제시하였다. 이하에서는 각 개발 단계별 보안활동에 대해 자세히 설명한다.

1. 개발준비

개발준비 단계에서는, 개발공정 단계별 AI 특화 보안활동 계획을 수립한다. 해당

단계에서의 산출물, 보안활동 계획의 예시로 <표 4> 자체가 활용될 수 있으나, 사업에 맞게 내용을 조정해야 할 것이다.

추가로, 소프트웨어 수명주기 선택 시 소프트웨어 도입 이후 유지보수 기간 내에, 개발단계에서 예상치 못한 보안사고가 발생할 경우, 이에 대한 보안대책을 수립, 구현하는 계획을 사업수행계획서에 포함해야 한다. AI의 행동을 완벽히 예측하는 것은 불가능하므로, 기존 전통적인 소프트웨어보다 AI의 예상치 못한 동작에 따른 보안사고가 발생할 가능성이 매우 높다. 따라서, 운용 중 보안사고에 대한 후속조치 계획을 수립하여, 지속적인 보안 업데이트를 보장하여야 한다.

2. 분석 - 시스템 요구사항 분석

시스템 수준에서 AI 고유의 공격표면을 식별하고 해당 공격표면에 대한 보안대책 요구사항을 식별한다. 도입될 시스템의 기능과 사용자층, 운용환경 등 전반적인 분석을 통해, 모든 잠재적 공격표면을 식별하는 단계이다. 4장에서 예를 들며 분석한 것과 같이, 도입하고자 하는 시스템 고유의 공격표면과 취약점들을 식별한다. 예를 들어, 정보보호체계와 무인 기지경계시스템은 각자 고유의 공격표면과 취약점들을 가지고 있을 것이다. 정보보호체계는 무인 기지경계시스템에 비해 데이터 중독 가능성이 더 높을 것이며, 무인 기지경계시스템은 탐색 공격보다 우회/기만 공격에 보다 주의를 기울여야 할 것이다. 이처럼, 도입하고자 하는 시스템에 대한 전체적 분석을 통해 잠재적인 취약점들을 도출해 내고, 이들에 대한 보안대책 요구를 시스템요구사항명세서에 명시한다. 명시된 시스템 요구사항들은, 이후 시스템 구조설계 혹은, 소프트웨어 구조설계 단계에서 그 대책이 제시되어야 한다.

3. 분석 - 시스템 구조설계

시스템 요구사항 분석 단계에서 식별된 취약점 혹은 이후 단계인 소프트웨어 구조설계에서 식별된 취약점들에 대해, 5장에서 기술한 것과 같이 시스템 수준의

보안대책을 수립하고, 이를 시스템설계기술서에 명시한다. 시스템 수준의 보안대책의 예로, 우회/기만 공격의 차단을 위해 사용자의 입력이 필터링 소프트웨어를 거친 후 AI에 입력되는 등의 대책을 생각할 수 있다. 혹은, AI 모델이 개인정보가 포함된 출력을 생성한 경우, 이를 바로 사용자에게 제공하지 않고, 별도의 필터링 소프트웨어가 개인정보를 없앤 후 수정된 출력을 사용자에게 전달하도록 시스템을 설계할 수 있다. 제도적 보안대책으로, 악의적인 입력을 금지하는 사용규정을 수립하여, 미연에 보안사고를 방지할 수도 있다. 시스템 수준의 보안대책은 모델 수준에서 해결할 수 없는 취약점들을 보완할 수 있다. 단, 이러한 시스템 수준의 보안대책의 이점을 적극적으로 활용하기 위해선 시스템 구조설계 단계와 소프트웨어 요구사항 분석 단계가, 일방적이 아닌 유기적으로 진행되어야 한다.

4. 분석 - 소프트웨어 요구사항 분석

소프트웨어 요구사항 분석 단계에서는, 시스템요구사항명세서 내 기능적 요구사항을 달성하기 위해 채택된 AI 유형의 고유 취약점을 식별하고, 이에 대한 보안대책 요구사항을 소프트웨어요구사항명세서에 포함한다. 예를 들어, 무인 경계시스템의 거동수상자 자동 탐지 기능을 구현하기 위해 동영상 내 객체를 자동 인식하는 AI 알고리즘을 채택하였다고 할 때, 해당 AI 알고리즘의 취약점을 분석한다. 다른 예로, 외부에 공개된 사전학습된 거대언어모델을 가져와 미세조정을 실시할 경우, 사전학습모델의 취약점들을 분석한다. 이러한 분석을 통해 도출된 잠재적 취약성과 이에 따른 보안대책 요구사항을 소프트웨어요구사항명세서에 포함한다. 앞서 기술했듯, 모델 수준의 취약점들은 모델 자체적인 보안대책뿐만 아니라, 시스템적 보안대책으로도 완화할 수 있다. 따라서, 모델 수준의 취약점을 시스템 수준에서 보완하기 위해선 이전 단계인 시스템 구조설계와 유기적으로 수행되어야 한다.

5. 설계 - 소프트웨어 구조설계

소프트웨어 구조설계 단계에선 어떠한 유형의 대응기법을 적용할 것인지를 설계

에 반영한다. 예를 들어, 데이터 중복 취약성을 극복하기 위해, 학습 전 데이터를 정화하는 기법이나, 중복된 데이터에 영향을 적게 받으며 학습하는 최적화 기법, 둘 중 하나 혹은 둘 모두를 소프트웨어 설계에 반영할 수 있다. 우회/기만 공격의 취약성을 극복하기 위해, 적대적 예제를 추가로 학습시키는 기법이나, 다양한 하부 모델의 중간결과를 종합하여 최종결과를 도출하는 앙상블 기법, 둘 중 하나 혹은 둘 모두를 소프트웨어 설계에 반영할 수 있다. 소프트웨어 구조설계 단계에선, 어떠한 유형의 기법을 적용할지를 결정하여 구조설계에 반영하고, 구체적인 기법 선정과 어떻게 구현할 것인지는 소프트웨어 상세설계 단계에서 결정한다.

6. 설계 - 소프트웨어 상세설계

소프트웨어 구조설계에서 선정한 방법을 구현하기 위해 어떠한 상세 기법을 적용할지를 결정하여 설계한다. 예로, 데이터의 중복 여부를 검증하고 이를 정화하는 기법은 여러 기법이 존재한다. Chen et al.(2021)은 학습데이터 세트의 메타데이터와 통계적 속성을 고려하여 데이터의 특징을 도출해 내고, 특징의 패턴이 이상한 데이터를 중복데이터로 분류하여 제거하는 기법을 제시하였다. Peri et al.(2020)은 데이터세트 내에서 데이터들을 유사도에 따라 군집화한 후, 해당 군집 내에서 특징이 다른 데이터들을 중복데이터로 분류하여 제거하는 기법을 제시하였다. 다양한 데이터 정화 기법처럼, 우회/기만 공격을 방어하는 기법 유형, 탐색 공격을 방어하는 기법 유형 또한 여러 기법이 존재한다. 그중 어느 기법을 적용할지를, 학습데이터에 대한 적용 가능성, 모델과의 호환성 등을 고려하여 소프트웨어설계기술서에 반영한다. 또한, 해당 기법의 효과성을 검증하기 위한 단위시험계획을 그 시험평가기준과 함께 수립한다. 만약 해당 기법이 단일시험이 불가하다면 통합시험계획에 포함하여 실시할 수 있다. 해당 대응기법이 통합된 소프트웨어에서도 잘 동작하는지 확인하는 절차를 수립하여 통합시험계획에 반영한다.

7. 구현 및 테스트 - 소프트웨어 코딩 및 단위시험

설계단계에서 결정된 대응기법을 실제로 구현하고 이에 대한 단위시험을 실시, 결과를 제출한다. 설계단계에서 결정된 대응기법 적용이 불가능하거나, 그 성능이 기대에 못 미치는 경우, 동일한 또는 유사한 효과를 기대할 수 있는 다른 대응기법을 적용할 수 있으며, 이때에는 소요제기기관, 집행기관과 협의하여 소프트웨어설계기술서를 수정하여 갱신한다. AI 개발의 특성상, 그 성능은 구현 및 시험 이후에 확인할 수 있는 경우가 대다수이다. 즉, 적용하여 시험해 보기 전까지 그 성능을 보장할 수가 없다. 그러므로, 적용 결과가 기대에 못 미치는 경우, 이에 대한 대안을 찾아 설계에 수정, 반영하여야 한다. 단위시험이 불가능한 대응기법의 경우, 소프트웨어 통합시험에서 평가한다.

8. 구현 및 테스트 - 소프트웨어 통합 및 자격시험

AI 모델의 전체적 성능을 평가할 때, 악의적 입력 실험을 통해 모델의 공격에 대한 견고성을 시험한다. 예를 들어, 수폴로 위장한 사람이 침입하는 동영상과 동영상 기반 침입탐지 AI 모델에 입력하고 AI 모델이 침입자를 탐지할 수 있는지를 시험하여, AI 모델의 적대적 공격에 대한 면역력을 평가한다. 또는, 시스템 구조설계 단계에서 사용자의 입력을 필터링하는 소프트웨어의 도입을 결정한 경우, 해당 소프트웨어의 필터링 기능을 시험한다. 단위시험에서 평가하지 못한 대응기법의 성능시험 또한, 소프트웨어 통합시험 시 실시한다.

9. 구현 및 테스트 - 시스템 통합 및 자격시험

시스템 구조설계에 반영한 시스템 수준의 보안대책을 시험 평가한다. 예를 들어, 사용자의 악의적 입력을 금지하는 내용의 사용지침서 내 반영 여부를 확인한다. 또는, 인공지능 기반의 인사정보체계에 대해 타인의 개인정보를 추출하고자 하는

입력이 입력되었을 때, 사용자 입력 필터링 소프트웨어부터 시작하여 인공지능 기반의 인사정보체계, 출력 필터링 소프트웨어까지의 일련의 동작을 시험한다.

10. 인도 - 시스템 인수 지원

개발준비 단계에서 수립한 유지보수계획에 따라, 예상치 못한 보안사고 발생 혹은 취약점 식별 시 이를 방지하기 위한 대책을 수립, 구현한다. 또한, 시스템 로그에 대한 지속적 관제를 통해 보안사고를 미연에 방지하고 발생 시 즉각 대응할 수 있도록 한다.

본 장에서는, AI 고유 취약점들을 보완하기 위해, 국방정보시스템의 소프트웨어 개발공정의 세부 단계별 보안활동 가이드라인을 제시하였다. 국방정보시스템의 도입 시 제시한 모든 보안대책을 적용하여야 하는 것은 아니며, 해당 시스템의 사용환경과 특성 등을 종합적으로 고려하여, 최적의 보안대책을 선정, 적용하여야 한다. 무분별한 보안대책의 적용은, AI 모델 성능 자체에도 악영향을 미칠 수 있고, 사용 편리성과 접근성에도 제약을 가져올 수 있다. 이러한 점을 종합적으로 고려하여, 해당 국방정보시스템에 특화된 현실적이며 효과적인 보안대책을 수립 적용하여야 한다. 본 장에서 제시한 보안활동을 종합 정리하면 <표 4>와 같다.

<표 4> 국방정보시스템 개발공정 단계별 AI 보안활동 가이드라인

분 류		공통 보안 활동	공격 유형별 세분된 보안 활동		
			중독 공격	우회/기만 공격	탐색 공격
개발준비		·개발공정 단계별 AI 특화된 보안활동계획 수립			
		·유지보수 기간 내 보안사고 발생 시 후속조치계획 수립			
		산출물: 개발공정 단계별 보안활동 계획			
분석	시스템 요구 사항 분석	·시스템 수준에서 AI 취약점 식별 및 이에 대한 보안 대책 요구 사항 식별	·모델이 학습하는 데이터가 중독되었을 가능성을 판단	·사용 환경에서 우회/기만 공격의 가능성을 판단	·사용 환경에서 탐색 공격의 가능성을 판단
		산출물: 시스템요구사항명세서 내 AI 취약점 보안대책 요구사항 명시			

분 류		공통 보안 활동	공격 유형별 세분된 보안 활동		
			중독 공격	우회/기만 공격	탐색 공격
	시스템 구조 설계	· 공격표면에 대한 시스템 수준의 보안 대책 수립	· 중독된 데이터를 학습한 모델이 배치된 이후 기능 오류 상황 발생 시 시스템 수준의 대책 수립(예: 사용로그 기록 및 관제 절차 설계)	· 우회/기만 공격의 차단을 위한 시스템적 수준의 대책 수립(예: 사용자의 입력 필터링 단계 추가)	· 탐색 공격의 차단을 위한 시스템적 수준의 대책 수립(예: AI 모델의 출력 결과에 대한 필터링 단계 추가)
		산출물: 시스템설계기술서 내 시스템 수준의 보안대책 명시			
	소프트 웨어 요구 사항 분석	· 모델 수준에서 AI 고유의 취약점 식별 · (외부모델 활용 시) 외부모델의 취약점 검증	· 데이터의 검증 또는 정화 절차 요구사항 추가	· 우회/기만 공격에 대한 모델의 내성 강화 대책 요구사항 추가	· 탐색 공격에 대한 모델의 내성 강화 대책 요구사항 추가
		산출물: 소프트웨어요구사항명세서 내 AI 취약점 보안대책 요구사항 명시			
설 계	소프트 웨어 구조 설계	· 모델 수준의 취약점에 대한 모델 수준의 보안대책 수립	· 데이터 중독 취약점에 대한 대응기법 유형 선택(예: 데이터 정화기법 적용)	· 우회/기만 공격 취약점에 대한 대응기법 유형 선택(예: 적대적 생성 신경망을 통해 생성된 적대적 예시 추가 학습)	· 탐색 공격 취약점에 대한 대응기법 유형 선택(예: 시스템 프롬프트(System Prompt) 적용)
		산출물: 소프트웨어설계기술서 내 구현할 대응기법 유형 기술			
	소프트 웨어 상세 설계	· 모델 수준의 특정 대응기법 채택	· 데이터 중독 취약점을 보완할 수 있는 기법 채택(예, 특정 데이터 정화기법 채택, 중독데이터에 내성을 가진 최적화 기법 중 특정 기법을 채택)	· 우회/기만 공격 취약점을 보완할 수 있는 AI 기법 채택(예: 특정 적대적 생성 신경망 기법을 채택하여, 적대적 예제 생성 및 학습)	· 탐색 공격 취약점을 보완할 수 있는 AI 기법 채택(예: 시스템 프롬프트(System Prompt) 상세 문구 선정)
		산출물: 소프트웨어설계기술서 내 구현할 상세 대응기법 기술, 단위시험계획서 내 상세 대응기법에 대한 시험계획 기술			
구 현	소프트 웨어	· 보안대책 상세기법의 적용	· 채택한 상세기법 적용(예: 데이터셋의	· 우회/기만 공격 취약점을 보완하는	· 탐색 공격 취약점을 보완하는

분 류		공통 보안 활동	공격 유형별 세분된 보안 활동		
			중독 공격	우회/기만 공격	탐색 공격
및 테 스 트	코딩 및 단위 시험	·(적용 가능 시) 보안대책 상세기법의 단위시험	무결성 검증 결과 제시, 중독데이터에 내성을 가진 최적화 기법을 모델에 적용)	알고리즘을 모델에 적용	알고리즘을 모델에 적용
		산출물: 소스 코드, 상세 대응기법에 대한 단위시험절차 및 결과			
	소프트 웨어 통합 및 자격 시험	·보안대책 상세기법의 소프트웨어 통합시험	·상세기법 적용 전후 모델의 성능 비교표 제시(예: 정확 전 데이터를 학습한 모델과, 정확 후 데이터를 학습한 모델의 성능 비교표 제시)	·상세기법 적용 전후 모델의 성능 비교표 제시(예: 보완 알고리즘의 적용 전, 적용 후 모델에 대한 우회 공격 시험결과 비교표 제시)	·상세기법 적용 전후 모델의 성능 비교표 제시(예: 보완 알고리즘의 적용 전, 적용 후 모델에 대한 탐색 공격 시험결과 비교표 제시)
		산출물: 상세 대응기법에 대한 통합시험절차 및 결과			
	시스템 통합 및 자격 시험	·모델 수준의 보 안대책 상세기법 의 시스템 통합 시험 ·시스템 수준 보 안대책 시험평가	·데이터 중독 취약 점을 보완하는 시 스템 수준의 보안 대책 시험평가(예: 데이터 중독 모델 에 대한 상황부여 모의시험을 통해 시스템 수준의 보 안대책의 효과성 입증)	·우회/기만 공격 취약점을 보완하 는 시스템 수준의 보안대책 시험평 가(예: 악의적 입 력을 제한하는 사 용자 지침서 평 가)	·탐색 공격 취약점 을 보완하는 시스 템 수준의 보안대 책 시험평가(예: AI 출력 검증 모 델의 검증 성능평 가)
		산출물: 사용자지침서 및 운용자지침서 내에 시스템 수준의 보안대책 기술 시스템통합시험결과보고서 내 시스템 수준의 보안대책 시험평가 결과 포함			
인 도	시스템 설치	-			
	시스템 인수 지원	·신규 식별된 취약점에 대한 보안대책 수립 및 적용 ·시스템 로그에 대한 지속적인 관제			

VII. 결론

우리 군은 국방혁신 4.0을 기초로, 국방분야에 AI를 활용하기 위한 노력에 박차를 가하고 있다. 그 노력의 일환으로, 2024년 4월 국방부는 국방 AI 센터를 창설하였다(조아미·양동욱, 2024). AI를 적극 활용하기 위한 각 군의 노력 또한 지속되고 있다. 육군은 2024년 2월 육군 인공지능센터를 개설하였으며, 육군 전 영역에 AI 기술을 확산할 계획을 가지고 있다(국방일보, 2024). 그러나, AI 기술의 유망한 미래와 함께, 새로운 유형의 보안 취약점 또한 발견되고 있다. 보안을 최우선으로 뒀아 하는 국방분야의 특성상, AI의 국방분야 도입에 있어 AI의 보안 취약점들은 반드시 고려되어야 한다. 그럼에도 불구하고, 국방 AI 도입의 기대효과에 관한 관심에 비해 그에 따른 위협에 관한 관심은 적은 것이 현실이다.

이러한 관점에서 본 연구에선 AI를 적용한 국방정보시스템의 잠재적인 보안위협을 종합적으로 분석하였다. 또한, 도출된 보안위협을 계획, 개발단계에서부터 예방하고 완화할 수 있는 구체적인 보안활동과 그에 따른 산출물을 제시하는 보안활동 가이드라인을 제안함으로써 보안이 내재된 AI 적용 국방정보시스템 개발을 도모하고자 하였다.

추가적으로, 제안한 가이드라인은 기존의 국방정보시스템 개발단계에 기초하여 설계되었지만, AI 기반의 무기체계와 전력지원체계의 도입절차에 있어서도 일부 변형을 통해 적용이 가능할 것으로 기대된다.

마지막으로, 미래에 있을 AI와 관련된 군내 정책 및 제도에 대한 개선과 발전 노력에 있어, 보안 측면에서 본 연구가 방향성을 제시하길 기대한다. 「국방 사이버 보안 위험관리 지시」 등의 국방부 내 보안 관련 제도의 개정 시에 본 논문에서 설명한 AI 취약점들과 그 보안대책을 참고하여 별도의 AI 관련 보안 조항을 제정할 수 있을 것이다(국방부, 2024b).

논문 접수: 2024년 7월 28일
논문 수정: 2024년 10월 4일
게재 확정: 2024년 10월 10일

참고문헌

- 국가정보원. (2023). “챗GPT 등 생성형 AI 활용 보안 가이드라인.” 국가사이버안보센터.
<https://www.ncsc.go.kr:4018/> (검색일: 2024. 5. 14.).
- 국방부. (2023a). “국방 정보화업무 훈령.” 국방부훈령 제2842호.
- _____. (2023b). 『2023~2037 국방과학기술혁신 기본계획』. 국가전략정보포털.
<https://nsp.nanet.go.kr/> (검색일: 2024. 5. 22.).
- _____. (2024a). 『국방혁신 4.0 기본계획』. 국가전략정보포털. <https://nsp.nanet.go.kr/> (검색일: 2024. 6. 23.).
- _____. (2024b). “국방 사이버보안 위험관리 지시.” 국방부기타 제15호.
- _____. (2024c). “AI 과학기술 강군 육성’을 위한 발돋움, 「국방 데이터·인공지능 확산주간」 행사 개최.” 정책브리핑. <https://www.korea.kr/briefing/> (검색일: 2024. 10. 1.).
- 국방일보. (2024. 2. 26.). “국방혁신 4.0 핵심·AI’ 연구로 최정예 육군 건설 박차.” 『국방일보』.
https://kookbang.dema.mil.kr/newsWeb/20240219/4/ATCE_CTGR_0010030000/view.do (검색일: 2024. 5. 14.).
- 국회. (2024). “유럽연합 인공지능법.” 국회법률도서관. <https://law.nanet.go.kr/> (검색일: 2024. 9. 30.).
- 디지털플랫폼정부위원회. (2023). 『공공부문 초거대 AI 도입 활용을 위한 가이드라인』. 디지털플랫폼정부위원회 <https://www.dpg.go.kr/DPG/main/index.do> (검색일: 2024. 5. 16.).
- 박규도·이영란. (2023). “AI 기반 국방정보시스템 개발 생명주기 단계별 보안 활동 수행 방안.” 『정보보호학회논문지』, 제33권 제3호. pp. 577-589.
- 법제처. (2024). 유럽의회, 「AI법」 가결. 세계법제정보센터. <https://world.moleg.go.kr/> (검색일: 2024. 9. 30.).
- 윤정현. (2021). “국방 분야 인공지능 기술 도입의 주요 쟁점과 활용 제고 방안.” 『과학기술정책』, 제279호. pp. 1-55.
- 조아미·양동욱. (2024. 4. 1.). “AI 첨단전력 확보…근무환경 개선·병력감축 대비한다.”

『국방일보』.

https://kookbang.dema.mil.kr/newsWeb/20240402/14/ATCE_CTGR_0010010000/view.do (검색일: 2024. 6. 6.).

- Akhtar, N., Liu, J., & Mian, A. (2018). "Defense against universal adversarial perturbations." In *Proceedings of the IEEE conference on computer vision and pattern recognition*. 3389-3398.
- Ali, M., Hu, Y. F., Luong, D. K., Oguntala, G., Li, J. P., & Abdo, K. (2020, October). "Adversarial attacks on ai based intrusion detection system for heterogeneous wireless communications networks." In *2020 AIAA/IEEE 39th Digital Avionics Systems Conference (DASC)*. IEEE. pp. 1-6.
- Ban, Y., & Dong, Y. (2022). "Pre-trained adversarial perturbations." *Advances in Neural Information Processing Systems*, 35, 1196-1209.
- Carlini, N., Tramer, F., Wallace, E., Jagielski, M., Herbert-Voss, A., Lee, K., ... & Raffel, C. (2021). "Extracting training data from large language models." In *30th USENIX Security Symposium(USENIX Security 21)*. pp. 2633-2650.
- Chakraborty, A., Alam, M., Dey, V., Chattopadhyay, A., & Mukhopadhyay, D. (2021). "A survey on adversarial attacks and defences." *CAAI Transactions on Intelligence Technology*, 6(1). 25-45.
- Chen, J., Zhang, X., Zhang, R., Wang, C., & Liu, L. (2021). "De-pois: An attack-agnostic defense against data poisoning attacks." *IEEE Transactions on Information Forensics and Security*, 16. 3412-3425.
- Department Of Navy Chief Information Officer. (2023). "DON Guidance on the Use of Generative Artificial Intelligence and Large Language Models." The United State of America Departement Of Navy.
- Easley, Mikayla. (2024. 8. 27.). "Air Force releases new tool to track development, spending on AI efforts." *Defensescoop*. <https://defensescoop.com/> (검색일: 2024. 10. 1.).
- Helbling, A., Phute, M., Hull, M., & Chau, D. H. (2023). "Llm self defense: By self examination, llms know they are being tricked." *arXiv preprint arXiv:2308.07308*.
- Inan, H., Upasani, K., Chi, J., Rungta, R., Iyer, K., Mao, Y., ... & Khabsa, M. (2023). "Llama guard: Llm-based input-output safeguard for human-ai conversations."

- arXiv preprint arXiv:2312.06674.
- ISO/IEC. (2020). *Information Technology -Artificial Intelligence- Overview of Trustworthiness in Artificial Intelligence*. Switzerland: ISO/IEC.
- JTC1. (2024). ISO/IEC JTC 1/SC 42 Artificial Intelligence. JTC1. <https://jtc1info.org/> (검색일: 2024. 10. 2.).
- Kurita, K., Michel, P., & Neubig, G. (2020). “Weight poisoning attacks on pre-trained models.” arXiv preprint arXiv:2004.06660.
- Lee, Y. B., Choi, M. W., & Lee, M. H. (2023). “Test and Evaluation Procedures of Defense AI System linked to the ROK Defense Acquisition System.” *Journal of Society of Korea Industrial and Systems Engineering*, 46(4). 229-237.
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). “Retrieval-augmented generation for knowledge-intensive nlp tasks.” *Advances in Neural Information Processing Systems*, 33. 9459-9474.
- Long, T., Gao, Q., Xu, L., & Zhou, Z. (2022). “A survey on adversarial attacks in computer vision: Taxonomy, visualization and future directions.” *Computers & Security*, 121, 102847.
- National Cyber Security Centre. (2023). *Guidelines for secure AI system development*. The United Kingdom: National Cyber Security Centre.
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., ... & Lowe, R. (2022). “Training language models to follow instructions with human feedback.” *Advances in neural information processing systems*, 35. 27730-27744.
- Papernot, N., McDaniel, P., & Goodfellow, I. (2016). “Transferability in machine learning: from phenomena to black-box attacks using adversarial samples.” arXiv preprint arXiv:1605.07277.
- Peri, N., Gupta, N., Huang, W. R., Fowl, L., Zhu, C., Feizi, S., ... & Dickerson, J. P. (2020). “Deep k-nn defense against clean-label data poisoning attacks.” In *Computer Vision-ECCV 2020 Workshops: Glasgow, UK, August 23-28, 2020, Proceedings, Part I* 16. pp. 55-70. Springer International Publishing.
- Radford, A., Narasimhan, K., Salimans, T., & Sutskever, I. (2018). “Improving language understanding with unsupervised learning.” OpenAI.
- Robey, A., Wong, E., Hassani, H., & Pappas, G. J. (2023). “Smoothllm: Defending large

- language models against jailbreaking attacks.” arXiv preprint arXiv:2310.03684.
- Tian, Z., Cui, L., Liang, J., & Yu, S. (2022). “A comprehensive survey on poisoning attacks and countermeasures in machine learning.” *ACM Computing Surveys*, 55(8). 1-35.
- The Biden-Harris Administration(2023). “Executive Order on the Safe, Secure, and Trustworthy Development and Use of Artificial Intelligence.” The United State of America: The Biden-Harris administration executive order.
- Velasquez, A. (2021). “Guaranteeing AI Robustness Against Deception (GARD).” DARPA. <https://www.darpa.mil/> (검색일: 2024. 05. 31.).
- Wei, A., Haghtalab, N., & Steinhardt, J. (2024). “Jailbroken: How does llm safety training fail?” *Advances in Neural Information Processing Systems*, 36.
- Zeng, S., Zhang, J., He, P., Xing, Y., Liu, Y., Xu, H., ... & Tang, J. (2024). “The Good and The Bad: Exploring Privacy Issues in Retrieval-Augmented Generation (RAG).” arXiv preprint arXiv:2402.16893.
- Zhou, M., Wu, J., Liu, Y., Liu, S., & Zhu, C. (2020). “Dast: Data-free substitute training for adversarial attacks.” *In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. pp. 234-243.